Elastic Stack

David THIBAU - 2024

david.thibau@gmail.com

Agenda

• Introduction

- L'offre ELK
- Concepts de base
- Les APIs

Indexation et documents

- Document API
- Routing
- API Search Lite
- Distribution de la recherche

• Ingestion de données : Fleet beats et Logstash

- Les Beats
- Concepts logstash
- Syntaxe Configuration pipeline
- Principaux input, filter, codecs, outputs
- Résilience

Configuration d'index

- Types de données
- Contrôle du mapping
- Configuration d'index
- Gabarit d'index

Agenda (2)

Recherche avec DSL

- Syntaxe DSL et combinaison de clauses
- Recherche filtre
- Recherche full-text
- Agrégations
- Géolocalisation

• Analyse temps-réel avec Kibana

- Présentation
- Mise au point de tableau de bord
- Types de visualisation
- Management

Vers la production

- Architectures Ingestion
- Monitoring Logstash
- Architecture Indexation/Recherche
- Cycle de vie des index, gestion des shards
- Monitoring API ElasticSearch
- Exploitation

Introduction

L'offre Elastic Stack
Concepts de base
L'API Rest

Introduction

- Elastic Stack (avant ELK) est un groupe d'outils facilitant l'analyse et la visualisation temps-réel de données volumineuses
- Ces outils libres sont développés par la même structure, la société *Elastic*, qui encadre le développement communautaire et propose des services complémentaires (support, formation, intégration et hébergement cloud)

Principaux composants de la pile

- Elastic Stack est composé des outils suivants :
 - Elasticsearch : Base documentaire NoSQL basée sur le moteur de recherche Lucene
 - Logstash: Outil de traitement des traces qui exécutent différentes transformations, et exporte les données vers des destinations diverses dont les index ElasticSearch
 - Beats : Agents spécialisés permettant de fournir les données à logstash
 - Kibana est une application Angular permettant de visualiser les données présentes dans Elasticsearch

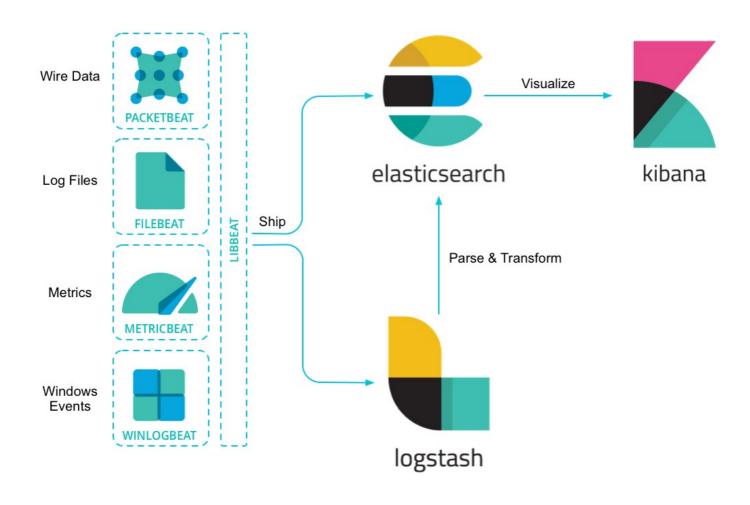
ElasticSearch

- ElasticSearch est un serveur offrant une API RestFul qui permet de :
 - Stocker et indexer des données
 (Contenu web ou bureautique, tweets, fichiers de traces, métriques de performance, données structurées RDBMS...)
 - D'exécuter des requêtes de recherche (structuré, full-text, langage naturel, geo-localisation)
 - Aggréger les données afin de calculer des KPI ou métriques

Caractéristiques

- Architecture massivement distribuée et scalable en volume et en charge
- => Adapté au Big Data, performance remarquable
- Haute disponibilité grâce à la réplication
- Muti-tenancy ou multi-index. Les données sont stockés dans des indexes dont les cycle de vie sont complètement indépendants
- Support pour différents types de requêtage
- => Recherche exacte, Full-text, vectoriel, agrégations
- Flexibilité: Stockage structuré des documents sans schéma préalable, possibilité d'ajouter des champs sur un schéma existant
- API RESTFul très cohérente et complète
- Open Source et commercial

Architecture



Offres connexes

- La société Elastic propose également des services payants :
 - X-Pack : fonctionnalités d'entreprise
 - Sécurité, Monitoring (avant release 8.x)
 - Alertes, Machine Learning
 - Application Performance Management
 - Reporting et planification
 - Elastic Cloud : Delegation de l'exploitation d'un cluster à Elastic

Solutions sur étagère

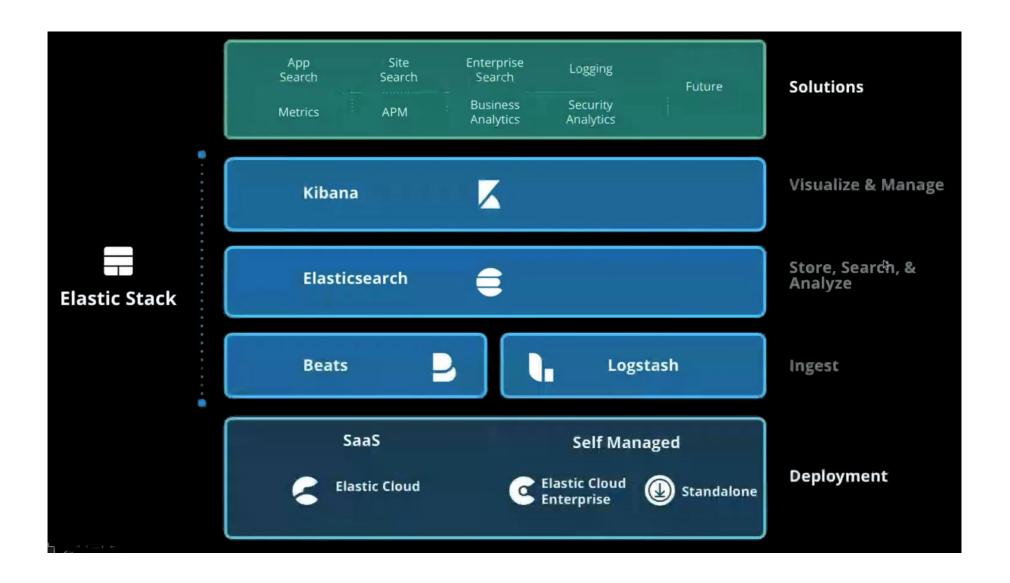
- Enterprise Search : Définir les sources de contenu (web, autre..), indexer le contenu et fournir des fonctionnalités de recherche
- *Elastic Observability*: Surveillez la consommation de CPU et de mémoire, agrégez les fichiers journaux, inspectez le trafic réseau, surveillez la des performances et l'usage des applications.

 Machine Learning pour détecter les anomalies et anticiper le futur
- Elastic Security : Détecter et répondre aux menaces

Elastic Use cases

Marketing Insights Centralized Logging Infrastructure Monitoring **Business Development** Operational Dashboards Application Management **Customer Sentiment** Security Analytics Edge/Device Monitoring **Business** Operational Marketing **Analytics Analytics Analytics** Developers Architects IT/Ops **Business Analysts** CTO/CIO/CDO

En résumé



Distributions

- La distribution permettant d'installer ElasticSearch est disponible sous plusieurs formes :
 - ZIP, TAR, DEB ou RPM
 - Également image Docker

Versions

- 8.0.0 : Février 2022

- 7.x : Avril 2019

– 6.x : Novembre 2017 à Décembre 2019

– 5.0.0 : Octobre 2016

– 2.4.1 : Septembre 2016

Installation ELS 8.x

- 1.Dézipper l'archive
- 2.Démarrer ELS bin/elasticsearch
- 3. Noter les crédentiels elastic et accéder à ELS curl https://localhost:9200/

Configuration

- Il existe plusieurs fichiers principaux de configuration :
 - *elasticsearch.yml* : Propriétés propres au noeud ELS
 - *jvm.options* : Options de la JVM
 - *log4j2.properties* : Verbosité et support de traces
 - Annuaire utilisateur et certificat SSL

La configuration par défaut permet de démarrer rapidement après une indexation.

En production, il faut quand même modifier certains paramètres. Par exemple :

- Le nom du nœud : **node.name**
- Les chemins : **paths**
- Le nom du cluster *cluster.name*
- L'interface réseau : network.host

elasticsearch.yml

- Les variables d'environnement sont accessibles : \${ENV_VAR}
- Certaines propriétés peuvent être demandées au démarrage : \${prompt.text}, \${prompt.secret}
- Les valeurs des propriétés peuvent être passées en ligne de commande.
 - ./elasticsearch -Enode.name=David

Bootstrap check

- Au démarrage ELS effectue des vérifications sur l'environnement . Si ces vérifications échouent :
 - En mode développement, des warning sont affichés dans les logs
 - En mode production (écoute sur une adresse publique), ELS ne démarre pas
- Ces vérifications concernent :
 - Dimensionnement de la heap pour éviter les redimensionnements et le swap
 - Limite sur les nombre de descripteurs de fichiers très élevée (65,536)
 - Autoriser 2048 threads
 - Taille et zones de la mémoire virtuelle (pour le code natif Lucene)
 - Le type de JVM (interdit les JVM client)
 - Le garbage collector (interdit la collecte série), la collecte Garbage First si la JVM est trop vieille
 - Filtre sur les appels système
 - Vérification sur le comportement lors d'erreur JVM ou de OutOfMemory

Introduction

L'offre

Concepts de base

Les APIs

Cluster

- Un cluster est un ensemble de serveurs (nœuds) qui contient l'intégralité des données et offre des capacités de recherche sur les différents nœuds
 - Il est identifié par son nom unique sur le réseau local (par défaut : "elasticsearch").
 - => Un cluster peut être mono-noeud
 - => Un nœud ne peut pas appartenir à 2 clusters distincts

Nœud

- Un nœud est un processus els identifié par un nom unique qui a rejoint un cluster
 - Le nombre de nœuds dans un cluster n'est pas limité, les nœud peuvent être ajoutés supprimés sans (trop) perturber le cluster
 - Un nœud peut avoir un ou plusieurs rôles :
 - master : Peut être élu pour coordonner le cluster
 - data : Stocke les données
 - *ingest* : Ingère les données
 - *ml* : Exécutes des jobs de Machine Learning

- ...

Nœud maître

- Dans un cluster un nœud est élu comme nœud maître, c'est lui qui est en charge de gérer la configuration du cluster comme la création d'index, l'ajout de nœud dans le cluster
- Pour toutes les opérations sur les documents (indexation, recherche), chaque nœud ayant le rôle adéquat est interchangeable et un client peut s'adresser à n'importe lequel des nœuds

Index

- Un index est une collection de documents qui ont des caractéristiques similaires
 - Par exemple un index pour les données client, un autre pour le catalogue produits et encore un autre pour les commandes
- Un index est identifié par un nom (en minuscule)
 - Le nom est utilisé pour les opérations de mise à jour ou de recherche
- Dans un cluster, on peut définir autant d'index que l'on veut

Shard

- Un index peut stocker une très grande quantité de documents qui peuvent excéder les limites d'un simple nœud.
- Pour pallier ce problème, ELS permet de sousdiviser un index en plusieurs parties nommées shards
 - Le nombre de shards est défini à la création de l'index
- Chaque shard est un index indépendant contenant un sous-ensemble des données hébergé sur un nœud data du cluster

Apports du sharding

- Le sharding permet :
 - De scaler le volume de contenu
 - De distribuer et paralléliser les opérations
 => augmenter les performances
- La mécanique interne de distribution lors de l'indexation et d'agrégation de résultat lors d'une recherche est complètement gérée par ELS et donc transparente pour l'utilisateur

Réplica

- Pour pallier à toute défaillance, un shard peut être répliqué
- Le nombre de réplique est défini à la création mais peut être modifié dynamiquement
- La réplication permet
 - La haute-disponibilité dans le cas d'une défaillance d'un nœud (Une réplique ne réside jamais sur le nœud hébergeant le shard primaire)
 - De scaler le volume des requêtes car les recherches peuvent être exécutées sur toutes les répliques en parallèle.

lacksquare

Document

- Un document est l'unité basique d'information stocké par les shards.
- Il est constitué d'un ensemble de champs typés
- Il peut être représenté avec JSON

Data Stream

- Un flux de données ou data stream stocke des évènements sur plusieurs index tout en offrant une seule ressource nommée pour les requêtes d'indexation ou de recherche
 - Les flux de données sont bien adaptés aux données générées en continu.
- Le data stream achemine automatiquement les requêtes d'indexation vers le bon index.
- Des stratégies d'ILM¹ permettent de préciser le cycle de vie des données.

Introduction

L'offre Elastic Stack Concepts de base Les APIs

API d'ELS

- ELS expose donc une API REST utilisant JSON
- L'API est divisée en catégorie
 - API document (CRUD sur document)
 - API d'index (CRUD sur Index)
 - API datastream : Flux de données (collections d'index datés)
 - API de recherche (_search)
 - API cluster : monitoring du cluster (_cluster)
 - API cat : Format de réponse tabulée pour gestion du cluster (_cat)
 - API *ingest* : Gestion des pipelines ELS
 - API *Logstash* : Gestion des pipelines logstash
 - API ML: Gestion des jobs de ML

- ...

Conventions

- Les différentes API REST d'ELS respectent un ensemble de conventions
 - Possibilité d'indiquer plusieurs indexs dans l'URL
 - Support des *Date*, *Math* dans les noms d'index. (Utilisation de timestamp dans les noms d'index et calculs de date)
 - Options/paramètres communs

Multiple index

 La plupart des APIs qui référencent un index peuvent s'effectuer sur plusieurs index :

```
test1,test2,test3
*test
+test*,-test3
all
```

Noms d'index avec Date Math

- La résolution d'index avec Date Math permet de restreindre les index utilisés en fonction d'une date.
- Il faut que les index soient nommés avec des dates
- La syntaxe est :

```
<static_name{date_math_expr{date_format|time_zone}}>
  - date_math_expr : Expression qui calcul une date
```

- date_format : Format de rendu
- time_zone : Fuseau horaire
- Exemples :

```
GET /<logstash-{now/d}>/_search => logstash-2017.03.05
GET /<logstash-{now/d-1d}>/_search => logstash-2017.03.04
GET /<logstash-{now/M-1M}>/ search => logstash-2017.02
```

Options communes (1)

- Les paramètres utilisent l'underscore casing
- ?pretty=true : JSON bien formatté
- ?format=yaml : Format yaml
- ?human=false : Si la réponse est traitée par un outil
- **Date Math**: +1h: Ajout d'une heure, -1d: Soustraction d'une journée, /d: Arrondi au jour le plus proche
- ?filter_path : Filtre de réponse, permettant de spécifier les données de la réponse Ex : GET /_cluster/state? pretty&filter_path=nodes

Options communes (2)

- **?flat_settings=true** : Les settings sont renvoyés en utilisant la notation « . » plutôt que la notation imbriquée
- ?error_trace=true : Inclut la stack trace dans la réponse
- Formats humains
 - Unités de temps : d, h, m, s, ms, micros, nanos
 - Unité de taille : b, kb, mb, gb, tb, pb
 - Nombre sans unités : k, m, g, t, p
 - Unités de distance : km, m, cm, mi, yd, ft

Clients possibles

- Il est possible d'utiliser les clients REST classiques : curl, navigateurs avec add-ons, SOAPUI, ...
- Elastic fournit des librairies en différents types de langage (Java, Javascrip, Python, Groovy, Php, .NET, Perl) pour intégrer les appels ELS dans vos applications. Ces librairies offrent du loadbalancing
- Enfin, le client le plus confortable est la Dev Console de Kibana

DevConsole Kibana

- Kibana, via sa DevConsole offre une interface utilisateur permettant d'interagir avec l'API REST d'Elasticsearch.
- Elle est composée de 2 onglets :
 - L'éditeur permettant de composer les requêtes
 - L'onglet de réponse
- La console comprend une syntaxe proche de Curl

```
GET /_search
{
    "query": {
        "match_all": {}
    }
}
```

Fonctionnalités

- La console permet une traduction des commandes CURL dans sa syntaxe
- Elle permet l'auto-complétion
- L'auto indentation
- Passage sur une seule ligne de requête (utile pour les requêtes BULK)
- Permet d'exécuter plusieurs requêtes
- Peut changer de serveur ElasticSearch
- Raccourcis clavier
- Historique des recherche
- Elle peut être désactivée (console.enabled: false)

Installation

- La version de Kibana doit correspondre rigoureusement à celle d'ElasticSearch
- La distribution inclut également la bonne version de Node.js
- Elle est disponible sous différents formats :
 - Archive compressée
 - Package debian ou rpm
 - Image Docker

Installation à partir d'une archive

```
wget
https://artifacts.elastic.co/downloads/kibana/kibana-
5.0.1-linux-x86_64.tar.gz
shalsum kibana-5.0.1-linux-x86_64.tar.gz
tar -xzf kibana-5.0.1-linux-x86_64.tar.gz
cd kibana/
./bin/kibana
```

Structure des répertoires

- *bin* : Script binaires dont le script de démarrage et le script d'installation de plugin
- config : Fichiers de configuration dont kibana.yml
- data : Emplacement des données, utilisé par Kibana et les plugins
- optimize : Code traduit.
- *plugins* : Emplacement des plugins. Chaque plugin correspond à un répertoire

Configuration

- Les propriétés de Kibana sont lues dans le fichier conf/kibana.yml au démarrage
- Les propriétés principales sont :
 - server.host, server.port : défaut localhost:5601
 - elasticsearch.hosts: http://localhost:9200
 - kibana.index : Index d'ElasticSearch utilisé pour stocker les recherches et les tableaux de bord
 - kibana.defaulAppId : L'application utilisée au démarrage Par défaut discover
 - *logging.dest*: Fichier pour les traces. Défaut *stdout*
 - logging.silent, logging.quiet, logging.verbose : Niveau de log

Indexation et Documents

Document API

Routing
API Search Lite
Distribution de la recherche

Introduction

- ElasticSearch est une base documentaire distribuée.
- Il est capable de stocker et retrouver des structures de données (sérialisées en documents JSON) en temps réel
- Les documents sont constitués de champs.
- Chaque champ a un type
- Certains champs de type texte sont indexés

Structure de données

- Un document est donc une structure de données.
 - Il contient des champs et chaque champ a une ou plusieurs valeurs (tableau)
- Un champ peut également être une structure de données. (Imbrication)
- Le format utilisé par ELS est le format JSON

Exemple

```
"name": "John Smith", // String
"age": 42,
                        // Nombre
"confirmed": true, // Booléen
"join date": "2014-06-01", // Date
"home": {
                        // Imbrication
 "lat": 51.5,
 "lon": 0.1
              // tableau de données
"accounts": [
 "type": "facebook",
 "id": "johnsmith"
 }, {
 "type": "twitter",
 "id": "johnsmith"
```

Méta-données

- Des méta-données sont également associées à chaque document.
- Les principales méta-données sont :
 - _index : L'emplacement où est stocké le document
 - _id : L'identifiant unique
 - version: Version du document

- ...

Introduction

- L'API document est l'API permettant les opérations CRUD sur la base documentaire
 - Création : POST
 - Récupération à partir de l'ID : GET
 - Mise à jour : PUT
 - Suppression : DELETE

Indexation et *id* de document

- Un document est identifié par ses métadonnées _index , _type et _id.
- Lors de l'indexation (insertion dans la base Elastic), il est possible de fournir l'ID ou de laisser ELS le générer

Exemple avec Id

```
POST /{index}/_doc/{id}
  "field": "value",
  "_index": {index},
  "_type": "_doc",
  "_id": {id},
  "_version": 1,
  "created": true
```

Exemple sans Id

```
POST {index}/_doc
  "field": "value",
  "_index": {index},
  "_type": "_doc",
  "_id": "wM00SFhDQXGZAWDf0-drSA",
  "_version": 1,
  "created": true
```

Récupération d'un document

• La récupérant d'un document peut s'effectuer en fournissant l'identifiant complet :

GET /{index}/_doc/{id}?pretty

La réponse contient le document et ses méta-données.
 Exemple :

```
{ "_index" : "website",
    "_type": "_doc",

    "_id" : "123",
    "_version" : 1,

    "found" : true,
    "_source" : {
        "title": "My first blog entry",
        "text": "Just trying this out...",
        "date":"2014/01/01" } }
```

Mise à jour

 Les documents stockés par ELS sont immuables.

=> La mise à jour d'un document consiste à indexer une nouvelle version et à supprimer l'ancienne.

 La suppression est asynchrone et s'effectue en mode batch (suppression de toutes les répliques)

Mise à jour d'un document

```
PUT /website/_doc/123
{
"title": "My first blog entry",
"text": "I am starting to get the hang of this...",
"date": "2014/01/02"
"_index" : "website",
" type": " doc",
"_id" : "123",
"_version" : 2,
"created": false
```

Suppression d'un document

```
DELETE /website/ doc/123
  "found" : true,
  " index" : "website",
  " type": " doc",
  " id" : "123",
  " version" : 3
```

Mise à jour partielle

- Les documents sont immuables : ils ne peuvent pas être changés, seulement remplacés
 - La mise à jour de champs consiste donc à réindexer le document et supprimer l'ancien
- L'API _update utilise le paramètre doc pour fusionner les champs fournis avec les champs existants

Exemple

```
POST /website/_update/1
{
  "doc" : {
    "tags" : [ "testing" ],
    "views": 0
"_index" : "website",
"_type": "_doc",
"_id" : "1",
"_version" : 3
```

Utilisation de script

 Un script (Groovy ou Painless) peut être utilisé pour changer le contenu du champ _source en utilisant une variable de contexte : ctx. source

• Exemples :

```
POST /website/_update/1/ {
    "script" : "ctx._source.views+=1"
}
POST /website/_update/1 {
    "script" : {
        "source" : "ctx._source.tags.add(params.new_tag)",
        "params" : {
            "new_tag" : "search"
}    } }
```

• Les scripts peuvent également être chargés à partir de l'index particulier .scripts ou du disque du serveur. Ils peuvent être utilisés dans d'autres contextes qu'une mise à jour.

Bulk API

- L'API *bulk* permet d'effectuer plusieurs ordres de mise à jour (création, indexation, mise à jour, suppression) en 1 seule requête
 - => C'est le mode batch d'ELS.
- Attention : Chaque requête est traitée séparément. L'échec d'une requête n'a pas d'incidence sur les autres. L'API Bulk ne peut donc pas être utilisée pour mettre en place des transactions.

Format de la requête

• Le format de la requête est :

```
{ action: { metadata }}\n
{ request body }\n
{ action: { metadata }}\n
{ request body } \n
```

- Le format consiste à des documents JSON sur une ligne concaténer avec le caractère \n.
 - Chaque ligne (même la dernière) doit se terminer par \n simple ligne
 - Les lignes ne peuvent pas contenir d'autre \n => Le document
 JSON ne peut pas être joliment formattés

Syntaxe

- La ligne action/metadata spécifie :
 - l'action:
 - create: Création d'un document non existant
 - index : Création ou remplacement d'un document
 - *update* : Mise à jour partielle d'un document
 - *delete* : Suppression d'un document.
 - Les méta-données : _id, _index, _type

Exemple

```
POST /website/_bulk // website est l'index par défaut
{ "delete": { "_type": "_doc", "_id": "123" }}
{ "create": { "_index": "website2", "_type": "_doc", "_id": "123" }}
{ "title": "My first blog post" }
{ "index": { "_type": "_doc" }}
{ "title": "My second blog post" }
{ "update": { "_type": "_doc", "_id": "123"} }
{ "doc" : {"title" : "My updated blog post"} }
```

Réponse

```
"took": 4,
"errors": false,
"items": [
{ "delete": { "_index": "website",
  "_type": "_doc", " id": "123",
  " version":2,
  "status": 200,
  "found": true
}},
{ "create": { "_index": "website",
  "_type": "_doc" , "_id": "123",
  "_version": 3,
  "status": 201
}},
{ "create": { " index": "website",
  " type": " doc", " id": "EiwfApScQiiy7TIKFxRCTw",
  "version": 1,
  "status": 201
}},
{ "update": { "_index": "website",
  "_type": "_doc", "_id": "123",
  " version": 4,
  "status": 200
}} ] }}
```

Indexation et Documents

Document API

Routing

API Search Lite

Distribution de la recherche

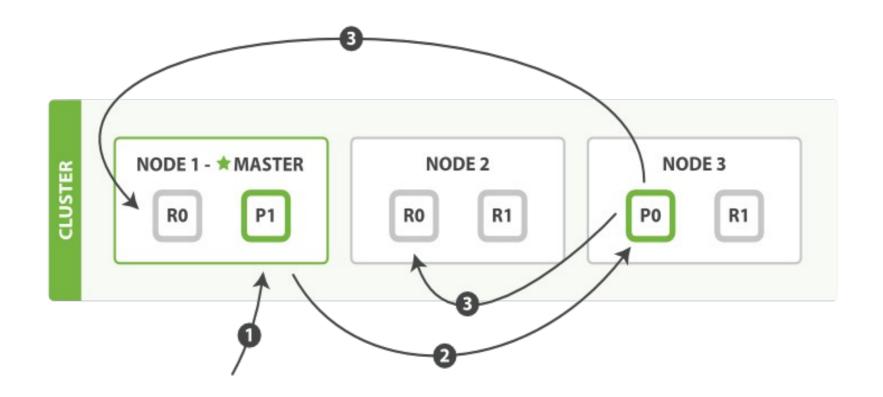
Résolution du shard primaire

 Lors de l'indexation, le document est d'abord stocké sur le shard primaire. La résolution du n° de shard s'effectue grâce à la formule :

```
shard = hash(routing) % number_of_primary_shards
```

 La valeur du paramètre *routing* est une chaîne arbitraire qui par défaut correspond à l'*id* du document mais peut être explicitement spécifiée
 Le nombre de shards primaires est donc fixé à la création de l'index et ne peut plus être changé

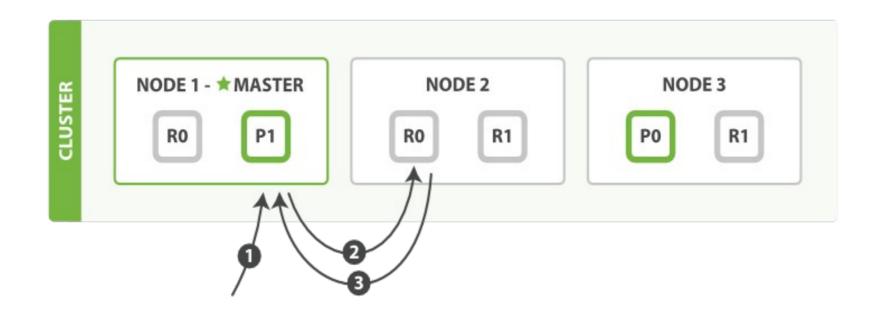
Séquence d'une mise à jour sur une architecture cluster



Séquence d'une mise à jour sur une architecture cluster (2)

- 1. Le client envoie une requête d'indexation ou suppression vers le nœud 1
- 2. Le nœud utilise l'id du document pour déduire que le document appartient au shard 0 . Il transfert la requête vers le nœud 3 , ou la copie primaire du shard 0 réside.
- 3. Le nœud 3 exécute la requête sur le shard primaire. Si elle réussit, il transfère la requête en parallèle aux répliques résidant sur le nœud 1 et le nœud 2. Une fois que les ordres de mises à jour des réplicas aboutissent, le nœud 3 répond au nœud 1 qui répond au client

Séquence pour la récupération d'un document



Séquence pour la récupération d'un document

- 1. Le client envoie une requête au nœud 1.
- 2. Le nœud utilise l'*id* du document pour déterminer que le document appartient au shard 0. Des copies de shard 0 existent sur les 3 nœuds Pour cette foisci, il transfert la requête au nœud 2.
- 3. Le nœud 2 retourne le document au nœud 1 qui le retourne au client.
- Pour les prochaines demandes de lecture, le nœud choisira un shard différent pour répartir la charge (algorithme Round-robin)

Indexation et Documents

Document API
Routing
API Search Lite
Distribution de la recherche

APIs de recherche

- Il y a donc 2 API de recherche :
 - Une version simple qui attend que tous ses paramètres soient passés dans la chaîne de requête
 - La version complète composée d'un corps de requête JSON qui utilise un langage riche de requête appelé DSL

Search Lite

- La version *lite* est cependant très puissante, elle permet à n'importe quel utilisateur d'exécuter des requêtes lourdes portant sur l'ensemble des champs des index.
- Ce type de requêtes peut être un trou de sécurité permettant à des utilisateurs d'accéder à des données confidentielles ou de faire tomber le cluster.
- => En production, on interdit généralement ce type d'API au profit de DSL

Recherche vide

GET /_search

 Retourne tous les documents de tous les index du cluster

Réponse

```
"hits" : {
  "total" : 14,
  "hits" : [ {
    "_index": "us",
    "_type": "tweet",
    "_id": "7",
    __score": 1,
"_source": {
     "date": "2014-09-17",
      "name": "John Smith",
      "tweet": "The Query DSL is really powerful and flexible",
      "user id": 2
    }
  }, ... RESULTS REMOVED ... ],
  "max score" : 1
}, tooks : 4,
  "_shards" : {
    "failed" : 0,
    "successful" : 10,
    "total" : 10
  "timed_out" : false
```

Champs de la réponse

- hits: Le nombre de document qui répondent à la requête, suivi d'un tableau contenant l'intégralité des 10 premiers documents. Chaque document a un élément _score qui indique sa pertinence. Par défaut, les documents sont triés par pertinence
- *took* : Le nombre de millisecondes pris par la requête
- shards: Le nombre total de shards ayant pris part à la requête. Certains peuvent avoir échoués
- timeout : Indique si la requête est tombée en timeout.
 Il faut avoir lancé une requête de type :
 GET / search?timeout=10ms

Limitation à un index

- _search : Tous les index
- /gb/_search : Tous les documents de l'index gb
- /gb,us/_search: Tous les documents de l'index gb et us
- /g*,u*/_search: Tous les documents des index commençant par g ou u

Pagination

- Par défaut, seul les 10 premiers documents sont retournés.
- ELS accepte les paramètres *from* et *size* pour contrôler la pagination :
 - size : indique le nombre de documents devant être retournés
 - from : indique l'indice du premier document retourné

Paramètre q

- L'API search lite prend le paramètre q qui spécifie la requête dans la syntaxe Lucene adéquate pour les champs full-text
- La chaîne est parsée en une série de
 - Termes : (Mot ou phrase)
 - Et d'opérateurs (AND/OR)
- La syntaxe support :
 - Les caractères joker et les expressions régulières
 - Le regroupement (parenthèses)
 - Les opérateurs booléens (OR par défaut, + : AND, : AND NOT)
 - Les intervalles : Ex : [1 TO 5]
 - Les opérateurs de comparaison

Exemples search lite

GET /_all/_search?q=tweet:elasticsearch

Tous les documents de type tweet dont le champ full

text match « elasticsearch »

```
+name:john +tweet:mary
GET /_search?q=%2Bname%3Ajohn+%2Btweet%3Amary
```

- Tous les documents dont le champ full-text name correspond à « john » et le champ tweet à « mary »
- Le préfixe indique des conditions qui ne doivent pas matcher

Champ _all

- Lors de l'indexation d'un document, ELS concatène toutes les valeurs de type string dans un champ full-text nommé _all
- C'est ce champ qui est utilisé si la requête ne précise pas de champ

```
GET /_search?q=mary
```

• Si le champ _all n'est pas utile, il est possible de le désactiver

Exemple plus complexe

- La recherche suivante utilise les critères suivants :
- Le champ name contient « mary » ou « john »
- La date est plus grande que « 2014-09-10 »
- Le champ _all contient soit les mots « aggregations » ou « geo »

+name:(mary john) +date:>2014-09-10 +(aggregations geo)

• Voir doc complète : https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-query-string-query.html#query-string-syntax

Autres Paramètres de la query string

- Les autres paramètres disponibles sont :
 - df: Le champ par défaut, utilisé lorsque aucun champ n'est précisé dans la requête
 - default_operator (AND/OR) : L'opérateur par défaut. Par défaut
 OR
 - *explain*: Une explication du score ou de l'erreur pour chaque hit
 - _source : false pour désactiver la récupération du champ _source.
 - Possibilité de ne récupérer que des parties du document avec _source_include & _source_exclude
 - sort : Le tri. Par exemple title:desc,_score
 - timeout : Timeout pour la recherche. A l'expiration du timeout, les hits trouvés sont retournés

Indexation et Documents

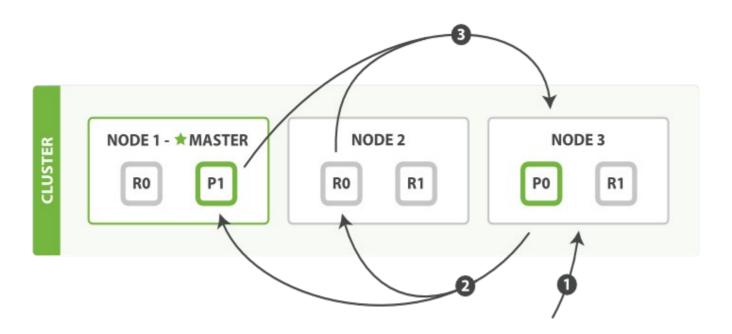
Document API
Routing
API Search Lite
Distribution de la recherche

Introduction

- La recherche nécessite un modèle d'exécution complexe les documents correspondant à la recherche sont dispersés sur les shards
- Une recherche doit consulter une copie de chaque shard de l'index ou des index sollicités
- Une fois trouvés ; les résultats des différents shards doivent être combinés en une liste unique afin que l'API puisse retourner une page de résultats
- La recherche est donc exécutée en 2 phases :
 - query
 - fetch.

Phase de requête

 Durant la 1ère phase, la requête est diffusée à une copie (primaire ou réplique) de tous les shards. Chaque shard exécute la recherche et construit une file à priorité des documents qui matchent

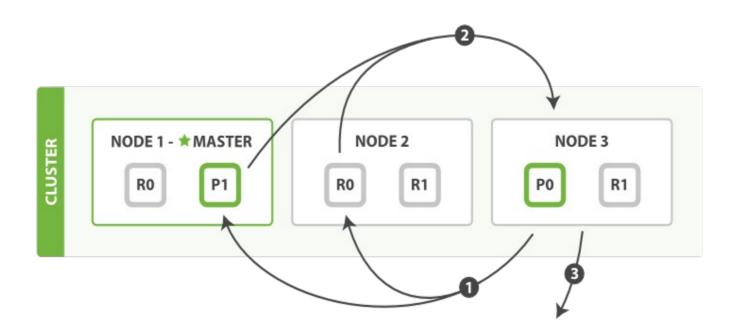


Phase de requête

- 1. Le client envoie une requête de recherche au nœud 3 qui crée une file à priorité vide de taille from + size .
- 2. Le nœud 3 transfère la requête à une copie de chaque shard de l'index. Chaque shard exécute la requête localement et ajoute le résultat dans une file à priorité locale de taille *from* + *size*.
- 3. Chaque shard retourne les IDs et les valeurs de tri de tous les documents de la file au nœud 3 qui fusionne ces valeurs dasn sa file de priorité

Phase fetch

• La phase de fetch consiste à récupérer les documents présents dans la file à priorité.



Phase fetch

- 1. Le nœud coordinateur identifie quels documents doivent être récupérés et produit une requête multiple GET aux shards.
- 2. Chaque shard charge les documents, les enrichi si nécessaire (surbrillance par exemple) et les retourne au nœud coordinateur
- 3. Lorsque tous les documents ont été récupérés, le coordinateur retourne les résultats au client.

Ingestion de données

Beats, exemple MetricBeat

Concepts Logstash
Syntaxe configuration Logstash
Principaux inputs, filtres, outputs
Résilience

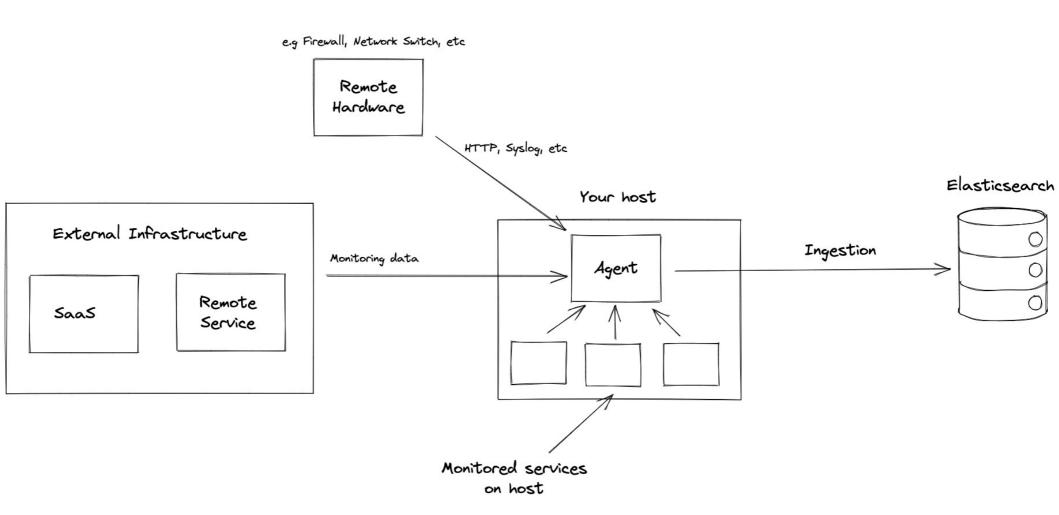
Introduction

- Elastic propose 2 méthodes principales pour envoyer des données à Elasticsearch :
 - Les Beats sont des convoyeurs de données installés sur les machines ciblent qui envoient régulièrement leur données vers logstash ou ElasticSearch.
 - Elastic Agent est un agent unique qui peut être déployé dans deux modes différents :
 - Géré par Fleet : les politiques et le cycle de vie de l'agent Elastic sont gérés de manière centralisée par l'application Fleet dans Kibana. L'application Intégrations permet d'ajouter de manière centralisée des intégrations avec d'autres services externes. (option recommandée).
 - Mode autonome : Les politiques sont appliquées manuellement à l'agent Elastic sous forme de fichier YAML.

Elastic Agent

- Elastic Agent offre un moyen unifié d'ajouter une surveillance pour les journaux, les métriques et d'autres types de données à un hôte.
- Il peut également protéger les hôtes contre les menaces de sécurité, interroger les données des systèmes d'exploitation, transférer les données des services ou du matériel distants, etc.
- Un agent unique facilite et accélère le déploiement de la surveillance sur l'ensemble de votre infrastructure.
- Chaque agent dispose d'une politique unique que vous pouvez mettre à jour pour ajouter des intégrations pour de nouvelles sources de données, des protections de sécurité, etc.

Architecture



Integrations

- Les intégrations Elastic offrent un moyen simple de connecter Elastic à des services et systèmes externes.
- Elles sont souvent livrées avec des ressources prêtes à l'emploi telles que des tableaux de bord, des visualisations et des pipelines pour extraire des champs structurés des journaux et des événements.
 - Disponibles pour les services et plateformes classiques Nginx ou AWS, fichiers journaux.
- Kibana fournit une interface utilisateur Web pour ajouter et gérer les intégrations (et les beats)

Beats vs Agent

- Elastic Agent et Beats ont des fonctionnalités similaires mais Elastic Agent présente des avantages :
 - Plus facile à déployer. Au lieu de déployer plusieurs Beats, vous déployez un seul Elastic Agent.
 - Plus facile à configurer. Vous n'avez plus besoin de définir et de gérer des fichiers de configuration distincts pour chaque Beat exécuté sur un hôte.
 - => Une seule stratégie d'agent qui spécifie les paramètres d'intégration à utiliser, et l'Elastic Agent génère la configuration requise par les programmes sous-jacents, comme Beats.
 - Gestion centralisée. Fleet dans Kibana.
 - Protection des endpoints: Protection des endpoints contre les menaces.

Beats vs Agent

Output	Beats	Fleet-managed Elastic Agent	Standalone Elastic Agent
Elasticsearch Service	~	✓	✓
Elasticsearch	•	✓	✓
Logstash	~	✓	✓
Kafka	~	✓	✓
Remote Elasticsearch	~	✓	✓
Redis	~	×	×
File	~	×	×
Console	•	×	×

Types de beats

- La distribution de beats fournie par ELK contient :
 - Packetbeat : Un analyseur de paquets réseau qui convoie des informations sur les transactions entre les différents serveurs applicatifs
 - *Filebeat*: Convoie les fichiers de trace des serveurs.
 - Metricbeat : Un agent de monitoring qui collecte des métriques sur l'OS et les services qui s'y exécutent
 - Winlogbeat : Événements Windows
- Il est possible de créer ses propre beats. ELK offre la librairie *libbeat* (écrit en Golang) comme support

Beats communautaires

- De nombreux beats communautaires sont également disponibles :
 - Apachebeat : Statut des serveurs Apache HTTPD
 - Elasticbeat : Statut d'un cluster ElasticSeearch. Il envoie ses données directement à Elasticsearch.
 - Execbeat : Exécute des commandes shells périodiquement et envoie la sortie standard vers Logstash ou Elasticsearch.
 - *hsbeat* : Métriques de performance de la VM Java HotSpot
 - httpbeat : Interroge périodiquement des endpoints HTTP(S) et envoie les réponses vers Logstash ou Elasticsearch.
 - jmxproxybeat : Lit les métriques JMX de Tomcat.
 - journalbeat : Convoie les logs de systemd/journald sur les systèmes Linux.

Beats communautaires (2)

- logstashbeat : Collecte les données de l'API de monitoring de Logstash et les index dans Elasticsearch.
- mysqlbeat : Exécute des requêtes SQL sur MySQL et envoie les résultats à Elasticsearch.
- nagioscheckbeat : Vérification Nagios et données de performance
- pingbeat : Envoie des ping ICMP pings à des cibles et stocke le round trip time (RTT) dans Elasticsearch.
- springbeat : Collecte les métriques de performance et de santé d'une application Spring Boot avec le module actuator activé.
- *twitterbeat* : Lit des tweets
- udpbeat : Envoie des traces via UDP
- wmibeat : Utilise WMI pour récupérer des métriques Windows configurable.

Caractéristiques communes

- Tous les beats ont des caractéristiques communes :
 - Leur fichiers de configuration sont des fichiers YAML
 - Ils contiennent les configurations par défaut pour des sorties vers logstash ou elasticsearch
 - Un fichier *-all.yml contient toutes les options possibles et fait figure de documentation
 - Lors de leur première utilisation, ils mettent à jour dans ELS un gabarit de mapping correspondant aux types des données qu'ils produisent
 - Ils sont distribués avec un ensemble de tableaux de bord Kibana prêt à l'emploi. Ces tableaux de bord sont importés manuellement ou automatiquement lors de la première utilisation

Metricbeats

- Metricbeat utilise des modules pour collecter les métriques. Chaque module se configure individuellement
 - system : Informations sur le cpu, le système de fichier, la mémoire, les processus, le réseau
 - Apache, nginx
 - Mysql, postgresql
 - MongoDb, CouchBase
 - Redis, Kafka, RabbitMQ
 - Docker, Kubernetes, ZooKeeper
 - Windows
 - ELS, Kibana, Logstash
- Metricbeat envoie ses données vers logstash ou ELS

Configuration

- La configuration consiste à :
 - Spécifier quels modules à exécuter
 - Spécifier les options générales de Metricbeat, les options communes à tous les beats
 - Configurer la file d'attente de traitement d'événements
 - Configurer la sortie
 - Filtrer et enrichir les données
 - Spécifier éventuellement une pipeline ELS
 - Indiquer l'hôte Kibana
 - Charger les tableaux de bord Kibana
 - Charger les gabarits d'index ELS
 - Fixer le niveau de trace

Ingestion de données

Beats, exemples FileBeat, MetricBeat

Concepts Logstash

Syntaxe configuration Logstash

Principaux inputs, filtres, outputs

Résilience

Logstash

- Logstash est un outil de collecte de données tempsréel capable d'unifier et de normaliser les données provenant de sources différentes
- A l'origine centré sur les fichiers de traces, il peut s'adapter à d'autres types d'événements
- Logstash est basé sur la notion de pipeline de traitement.
 Il permet de filtrer, mixer et orchestrer différentes entrées
- Extensible via des plugins, il se connecte à de nombreuses sources de données

Types de source

- Traces et métriques : Apache, log4j, syslog, Windows Event, JMX, ...
- Web : Requêtes HTTP, Twitter, Hook pour GitHub, JIRA, Polling d'endpoint HTTP
- Support de persistance : JDBC, NoSQL, *MQ
- <u>Capteurs diverses</u>: Mobiles, Domotique,
 Véhicules connectés, Capteur de santé

Enrichissement de données

- Logstash permet également d'enrichir les données d'entrées.
 - Géo-localisation à partir d'une adresse IP. (lookup vers un service)
 - Encodage/décodage de données
 - Normalisation de dates
 - Requêtes Elastic Search pour l'enrichissement
 - Anonymiser des informations sensibles

Structure répertoires

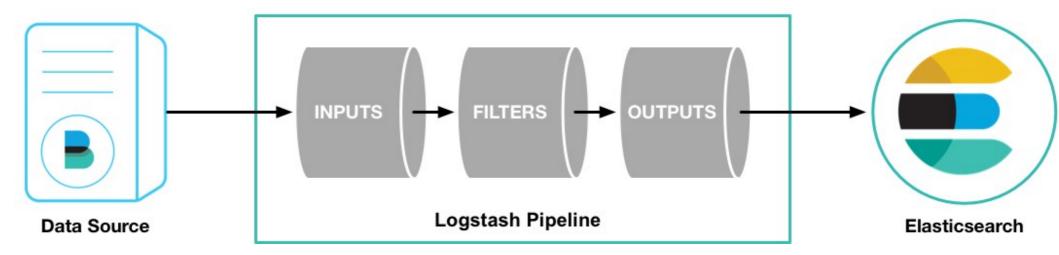
- **bin** : Scripts ; en particulier
 - logstash le script de démarrage
 - et logstash-plugin pour installer des plugins)
- config: Fichiers de configuration ; en particulier
 - logstash.yml
 - et *jvm.options*
- *logs* : Fichiers de traces, configurable via : *path.logs*
- *plugins*: plugins locaux (non Ruby-Gem). Chaque plugin est contenu dans un répertoire configurable via *path.plugins*

Plugins

- Il est possible d'ajouter des plugins à l'installation :
 - en utilisant le dépôt RubyGems.org Exemple :
 bin/logstash-plugin install logstash-output-kafka
 - En utilisant un chemin local : bin/logstash-plugin install /path/to/logstash-output-kafka-1.0.0.gem
- Les plugins peuvent ensuite être mis à jour bin/logstash-plugin update

Pipeline Logstash

- Une pipeline logstash a au minimum :
 - Un plugin d'entrée pour lire les données
 - Une plugin de sortie pour écrire les données
 - Optionnellement des filtres entre les 2



Configuration

 Les pipelines sont généralement configurées dans des fichiers :

```
# The # character at the beginning of a line indicates a comment. Use
# comments to describe your configuration.
input {
}
# The filter part of this file is commented out to indicate that it is
# optional.
# filter {
# #
}
output {
}
```

Ou la configuration peut être précisée sur la ligne de commande

```
bin/logstash -e 'input { stdin { } } output { stdout {} }'
```

Exemple

```
input {
    beats { port => "5043" }
}
filter {
    grok {
        match => { "message" => "%{COMBINEDAPACHELOG}"}
    }
    geoip {
        source => "clientip"
}
output {
    elasticsearch {
        hosts => [ "localhost:9200" ]
```

Multiple entrées/sorties

 Logstash est capable de traiter plusieurs entrées et les acheminer vers plusieurs sorties

```
input {
    twitter {
        consumer_key => "enter_your_consumer_key_here"
        consumer_secret => "enter_your_secret_here"
        keywords => ["cloud"]
        oauth_token => "enter_your_access_token_here"
        oauth_token_secret => "enter_your_access_token_secret_here"
    }
    beats {
        port => "5043"
    }
}
output {
    elasticsearch {
        hosts => ["IP Address 1:port1", "IP Address 2:port2", "IP Address 3"]
    }
    file {
        path => "/path/to/target/file"
    }
}
```

Les entrées

- Les entrées permettent d'insérer des données dans les pipelines *Logstash*.
- Les plus courant sont :
 - *file*: Lecture d'une fichier (<=> tail -f)
 - syslog : Écoute les messages syslog sur le port 514 et les parse au format RFC3164
 - redis: Lecture d'un serveur redis. Redis est souvent utilisé pour centraliser les événements provenant de différents installation Logstash
 - **beats** : Traite les événements de *FileBeats*

Champs

- Chaque événement traité par logstash est constitué de champs
 - Les champs deviendront les champs des documents indexés par ElasticSearch
 - Les filtres permettent de faire des transformations sur des champs :
 - Splitter un champ en plusieurs (grok)
 - Convertir le type de données
 - Ajouter/Supprimer des champs
 - •
 - Il est possible de conditionner l'exécution d'un filtre ou d'un plugins de sortie à la présence d'un champ

Les filtres

- Les filtres sont les traitements intermédiaires d'une pipeline Logstash
- Il peuvent s'appliquer selon des conditions, i.e. les champs d'un événement remplissent certains critères
- Les filtres les plus courants :
 - grok: Parse et structure un texte arbitraire. 120 patterns sont prédéfinis dans Logstash correspondant aux formats de logs les plus courant
 - *mutate*: Effectue des transformations sur les champs de l'événement (Renommage, suppression, remplacement, modification)
 - **drop**: Supprime un événement Ex : DEBUG
 - clone: Effectue une copie de l'événement en ajoutant ou enlevant des champs
 - *geoip*: Ajoute des informations géographiques à partir de l'adresse IP

Les sorties

- Les sorties sont la phase finales d'une pipeline
- Les sorties les plus courantes sont :
 - elasticsearch: Envoie les données à ElasticSearch pour indexation
 - file: écrit l'événement sur un fichier
 - graphite: Envoie les données à graphite, un outil open source pour stocker des données de graphiques http://graphite.readthedocs.io/en/latest/
 - statsd: Envoie vers le démon statsd qui écoute sur UDP, agrège des données et envoie à des services backend pluggable
 - *tcp/udp* : Envoie vers des sockets tcp ou udp

Codecs

- Les entrées et les sorties peuvent appliquer des codecs qui permettent d'encoder ou décoder les données sans utiliser de filtres particuliers
- Les codecs permettent de facilement séparer le transport de message du processus de sérialisation
- Les codecs les plus utilisés sont :
 - *json* : Encode ou décode les données au format JSON
 - multiline : fusionne des événements textes multi-ligne en une seule ligne. Ex : Exception Java et leur stacktrace
 - rubydebug : Utilisée pour le debugging. Permet de voir les champs trouvés par logstash

Options au démarrage

- Les autres options intéressantes de logstash sont :
 - -f -path.config : Chemin vers le fichier de configuration
 - --log.level LEVEL : fatal, error, warn, info, debug, trace
 - --config.debug : Si log.level = debug. Affiche dans le log les événements envoyés en sortie au format json (Sortie ruby)
 - -t, --config.test_and_exit : Vérifie la syntaxe de la configuration
 - -r, --config.reload.automatic : Permet des changements dynamiques de la configuration. On peut également activer à posteriori le rechargement automatique par kill -1 <pid>

Atelier: Installation logstash, premiers pas

Ingestion de données

Beats, exemples FileBeat, MetricBeat Concepts Logstash Syntaxe configuration Logstash Principaux inputs, filtres, outputs

Introduction

- Le fichier de configuration spécifie les plugins à utiliser et leur configuration
- La configuration d'un plugin consiste en
 - le nom du plugin
 - suivi par un block spécifiant des valeurs pour les propriétés de configuration
- Les valeurs fournies doivent respecter le type attendu
- Une syntaxe particulière permet de référencer les champs des événements
- Des structures de contrôle (test if) peuvent conditionner l'exécution d'un traitement

Types supportés

• Les blocs de configuration sont différents selon les plugins, mais les valeurs de configuration appartiennent aux types suivants :

Référence des champs

Pour référencer un champ de haut niveau,

- il suffit de spécifier le champ. Ex : agent.
- Ou utiliser la notation []. Ex : [agent]

Pour les champs imbriqués, il faut utiliser la notation []. Ex [ua][os]

```
"agent": "Mozilla/5.0 (compatible; MSIE 9.0)",
"ip": "192.168.24.44",
"request": "/index.html"
"response": {
    "status": 200,
    "bytes": 52353
},
"ua": {
    "os": "Windows 7"
}
```

Exemples sprintf

La notation **%{}**, nommée **sprintf**, permet de concaténer des valeurs statiques et les valeurs des champs

 Une notation spécifique permet de récupérer la date du jour dans un format particulier.

```
output {
   statsd {
     increment => "apache.%{[response][status]}"
   }
}

output {
  file {
    path => "/var/log/%{type}.%{+yyyy.MM.dd.HH}"
  }
}
```

Configuration conditionnelle

 La configuration conditionnelle s'obtient en utilisant des instructions if then else

```
if EXPRESSION {
    ...
} else if EXPRESSION {
    ...
} else {
    ...
}
```

Exemples

```
filter {
 if [action] == "login" {
   mutate { remove field => "secret" }
 } }
output {
 # Send production errors to pagerduty
 if [loglevel] == "ERROR" and [deployment] == "production" {
   pagerduty {
   } } }
if [foo] in ["hello", "world", "foo"] {
   mutate { add tag => "field in list" }
 }
L'expression if [foo] retourne false si :
• [foo] n'existe pas dans l'évènement,
• [foo] existe mais est false ou null
```

Le champ @metadata

- Il existe un champ spécial : @metadata
- Ce champ ne sera pas écrit sur les sorties par contre il peut être utilisé pendant tout le traitement Logstash

```
input { stdin { } }

filter {
    mutate { add_field => { "show" => "This data will be in the output" } }
    mutate { add_field => { "[@metadata][test]" => "Hello" } }
    mutate { add_field => { "[@metadata][no_show]" => "This data will not be in the output" } }
}

output {
    if [@metadata][test] == "Hello" {
        stdout { codec => rubydebug }
    }
}
```

Variables d'environnement

- une variable environnement peut être référencée par \${var} dans le fichier de configuration
 - Des références à des variables indéfinies provoquent des erreurs
 - Les variables sont sensibles à la casse
 - Une valeur par défaut peut être fournie par \${var:default value}.

Ingestion de données

Beats, exemples FileBeat, MetricBeat
Concepts Logstash
Syntaxe configuration Logstash
Principaux inputs, filtres, outputs
Résilience

Inputs

- Quelques inputs :
 - **beats** : Événements d'un beat
 - elasticsearch : Lit des résultats de requêtes à partir d'un cluster
 Flasticsearch
 - **exec**: Sortie d'une commande shell
 - *file* : Lecture de lignes de fichier
 - *generator* : Génère des évènements au hasard pour le test
 - *heartbeat* : Génère des évènements *heartbeat* pour le test
 - *jdbc* : Événements à partir de JDBC
 - Kafka, redis, rabbitmq, jms: Messaging
 - Tcp, udp, log4j, unix, syslog : Evènements sockets bas niveau

- ...

Exemples

```
input {
  beats {
    port => 5044
 file {
    path => "/var/log/*"
    exclude => "*.gz"
  generator {
    lines => [
      "line 1",
      "line 2",
      "line 3"
    # Emet toutes les lignes 3 fois.
    count => 3
```

Input file

- Input file est similaire à un tail -OF mais peut également lire un fichier depuis son début
- Par défaut, chaque événement correspond à une ligne
- Le plugin garde une trace de la position de lecture courante pour chaque fichier dans un fichier séparé nommé *sincedb*
- Les principales configuration :
 - path
 - start_position
 - exclude
 - ignore_older
 - delimiter

Quelques filtres

- cidr : Vérifie des adresses IP
- csv : Parse le format csv
- date : Parse des champs afin de déterminer le timestamp de l'événement
- dns: Effectue un lookup DNS
- *drop* : Supprime un événement
- elapsed : Calcul le temps entre 2 événements
- environment: Stocke des variables d'environnement comme champ metadata
- extractnumbers : Extrait des nombres à partir d'une string

Quelques filtres (2)

- geoip : Ajoute des informations latitude/longitude à partir d'une IP
- grok : Divise un champ en d'autres champs
- json : Parses les événements JSON
- json_encode : Sérialize un champ au format JSON
- metrics : Calcul des agrégations sur un évènements (Comptage, cadence)
- *mutate* : Transforme un champ
- prune : Filtre des événements à partir d'une liste rouge ou blanche
- range : Vérifie que la taille ou longueur d'un champs est dans un intervalle
- translate : Remplace les valeurs des champs à partir d'une table de hash ou fichier YAML
- *truncate* : Tronque les champ supérieur à une certaine longueur
- urldecode : Décode les champs URL-encoded
- useragent : Parse les chaînes user agent
- xml : Parse le format XML

Le filtre grok

- *grok* est sûrement le filtre le plus utilisé. Il permet de générer différents champs ELS à partir d'une ligne de log.
- Il s'appuie sur des patterns qui sont déposés par la communauté sur GitHub (+120) https://github.com/elastic/logstash/blob/v1.4.2/patterns/grok-patterns
- Les patterns s'appuient sur les regexp et des patterns spécifiques peuvent être déclarés
- Un pattern Grok s'écrit : %{SYNTAX:SEMANTIC}
 - SYNTAX est un pattern associé à une expression régulière
 - SEMANTIC est le nom de champ que l'on veut créer
- Il existe un site en ligne permettant de debugger une expression grok https://grokdebug.herokuapp.com/

Le filtre mutate

- Permet de multiples transformations, les options sont :
 - *convert* : Conversion de type
 - copy : Copie de champ dans un autre champ
 - gsub : Remplacement de chaînes de caractères à partir d'expression régulière
 - *lowercase* / *uppercase* : Passage en minuscule/majuscule
 - *join*, *merge* : Travaille sur des tableaux
 - rename : Renommage de champ
 - *replace*, *update* : Remplacement de valeur
 - *split* : Transforme un champ en tableau en utilisant un séparateur
 - *strip* : Supprime les espaces avant et après

Le filtre date

- Le filtre est utilisé pour parser des dates à partir de champ et utilisé cette date comme timestamp logstash. Les options sont :
 - match : Un tableau dont la première valeur est le champ parser et les autres valeurs les formats possibles
 - locale, timezone : Si pas présent dans le format du match, on peut préciser
 - target : Le champ stockant le résulat, par défaut @timestamp

Quelques Codecs

- Les codecs changent la représentation d'un événement. Ils sont utilisés à l'intérieur d'une entrée ou d'une sortie
 - gzip_lines : Lit du contenu encodé avec gzip
 - json : Lit du contenu JSON formatté.
 - json_lines : Lit du contenu JSON formatté sur une seule ligne (Bulk API de ELS)
 - *multiline* : Fusionne plusieurs lignes en 1 événement
 - rubydebug : Debug d'évènements

Événements multi-lignes

- Lors d'événements multi-lignes, Logstash doit savoir quels lignes doivent faire partie de l'événement unique
- Le traitement des multi-lignes est effectué en général en premier dans le pipeline et utilise le filtre ou le codec multiline
- 3 options importantes de configuration :
 - pattern: Expression régulière. Les lignes correspondantes sont considérées soit comme la suite des lignes précédentes ou le début d'un nouvel événement II est possible d'utiliser les gabarits de grok
 - what : Qui peut prendre 2 valeurs : previous ou next
 - negate : Qui permet d'exprimer la négation

Exemple stack trace Java

```
Exception in thread "main" java.lang.NullPointerException
    at com.example.myproject.Book.getTitle(Book.java:16)
    at com.example.myproject.Author.getBookTitles(Author.java:25)
    at com.example.myproject.Bootstrap.main(Bootstrap.java:14)
```

• Le filtre suivant indique qui si la ligne démarre avec des espaces, elle est considéré comme la suite de l'événement

```
input {
    stdin {
      codec => multiline {
        pattern => "^\s"
        what => "previous"
      }
    }
}
```

Les plugins outputs

Quelques outputs

- csv : Ecrit sur le disque au format CSV
- *elasticsearch* : Stocke dans Elasticsearch
- *email* : Envoie un email à une adresse spécifiée
- exec: Exécute une commande si un évènement correspond
- file: Ecrit dans un fichier
- **stdout**: Ecrit sur la sortie standard
- pipe : Evoie vers l'entrée standard d'un autre programmeHttp : Envoie sur un endpoint HTTP ou HTTPS
- *nagios*, *nagios_nsca*: Envoi vers Nagios
- tcp, udp, syslog, statsd, websocket : Sockets
- kafka, redis, rabbitMQ : Messaging

- ...

Output elasticsearch

- L'output *elasticsearch* contient de nombreuses options. Les plus importantes sont :
 - hosts: Les hôtes du cluster
 - index : Le nom de l'index. Exemple : logstash-%{+YYYY.MM.dd}. Attention, le nom influe sur le gabarit d'index utilisé
 - **template** : Un chemin vers le fichier template
 - template_name : Le nom du tempate côté ElasticSearch
 - template_overwrite (false) : Permet de mettre à jour le template utilisé
 - document_id : L'id du document (permet les mises à jour d'événements)
 - parent : Le document parent de l'événement (nested document)
 - pipeline : La pipeline côté ElasticSearch à utiliser
 - *routing* : Peut spécifier le shard à utiliser

Exemple complet log Apache

```
input {
  file {
   path => "/tmp/* log"
# Traitements différents en fonction du type de log
filter {
 if [path] =~ "access" {
   mutate { replace => { type => "apache access" } }
    grok {
      #gabarit connu par grok
      match => { "message" => "%{COMBINEDAPACHELOG}" }
    date {
      # Normalisation de la date
      match => [ "timestamp" , "dd/MMM/yyyy:HH:mm:ss Z" ]
  } else if [path] =~ "error" {
   mutate { replace => { type => "apache error" } }
  } else {
    mutate { replace => { type => "random logs" } }
output {
 elasticsearch { hosts => ["localhost:9200"] }
 stdout { codec => rubydebug }
```

Résultat pour une ligne de log d'accès

```
"message" \Rightarrow "127.0.0.1 - - [11/Dec/2013:00:01:45 -0800] \"GET
/xampp/status.php HTTP/1.1\" 200 3891 \"http://cadenza/xampp/navi.php\" \"Mozilla/5.0
(Macintosh; Intel Mac OS X 10.9; rv:25.0) Gecko/20100101 Firefox/25.0\"",
     "@timestamp" => "2013-12-11T08:01:45.000Z",
       "@version" => "1",
           "host" => "cadenza",
       "clientip" => "127.0.0.1",
          "ident" => "-",
           "auth" => "-",
      "timestamp" => "11/Dec/2013:00:01:45 -0800",
           "verb" => "GET",
        "request" => "/xampp/status.php",
    "httpversion" => "1.1",
       "response" => "200",
          "bytes" => "3891",
       "referrer" => "\"http://cadenza/xampp/navi.php\"",
          "agent" => "\"Mozilla/5.0 (Macintosh; Intel Mac OS X 10.9; rv:25.0)
Gecko/20100101 Firefox/25.0\""
```

Exemple complet syslog

```
input {
 tcp { port => 5000 type => syslog }
 udp { port => 5000 type => syslog } }
filter {
 if [type] == "syslog" {
   grok {
     match => { "message" => "%{SYSLOGTIMESTAMP:syslog timestamp} %{SYSLOGHOST:syslog hostname} %
{DATA:syslog program}(?:\[%{POSINT:syslog pid}\])?: %{GREEDYDATA:syslog message}" }
     add field => [ "received at", "%{@timestamp}" ]
     add field => [ "received from", "%{host}" ]
   }
   date { match => [ "syslog timestamp", "MMM d HH:mm:ss", "MMM dd HH:mm:ss" ] }
 } }
output {
  elasticsearch { hosts => ["localhost:9200"] }
  stdout { codec => rubydebug }
```

Modèle d'exécution d'une pipeline

- Le modèle d'exécution de Logstash distingue :
 - Les threads d'input traitant la réception des messages sur les différentes entrées. Une thread par input
 - Les worker threads exécutant les filtres et les sorties
- Les threads d'input écrivent les événements dans une file **synchronisée**, i.e les écritures se terminent lorsque la lecture par une worker thread s'effectue. (Pas de buffer)
 - Si les workers theads sont occupées, la thread d'input est bloquée
- Les worker threads traitent les événements par lots
 - Ils remplissent une file d'attente, lorsqu'elle atteint une certaine taille. Le lot d'événements est envoyé dans la pipeline
 - Ils utilisent également une file d'attente pour l'écriture sur les sorties
- Par défaut, les files d'attente des workers sont des files d'attente mémoire.
 - Lors d'un arrêt brusque de logstash, les événements dans la file mémoire sont perdus
 - Il est possible de configurer une file persistante

Options configurables de la pipeline

- 3 options de la commande en ligne jouant sur les performances sont configurable pour une pipeline
 - --pipeline.workers ou -w : Le nombre de workers par défaut 4
 - Généralement supérieur au nombre de CPU disponibles. Il faut augmenter ce chiffre afin que les CPU travaillent au maximum
 - --pipeline.batch.size ou -b : Nombre maximum d'événements qu'un worker peut collecter. Par défaut 125
 - Plus le nombre est grand, plus le débit et plus la mémoire augmente. Si on augmente trop ce chiffre, les performances se dégradent à cause des collectes mémoire
 - --pipeline.batch.delay : La latence de la pipeline. Par défaut 5 ms
 - Si aucun nouveau événement n'arrive sous ce délai. Les événements dans le batch sont traités. Ce paramètre nécessite rarement un tuning

Plusieurs pipelines

- Logstash permet d'exécuter plusieurs pipelines dans le même processus.
- Cela permet d'avoir des configurations de performance ou de durabilité différentes en fonction des entrées
- La configuration s'effectue par un fichier additionnel pipelines.yml placé dans path.settings
- Logstash est alors lancé sans l'argument -f

Exemple pipeline.yml

```
- pipeline.id: my-pipeline_1
  path.config: "/etc/path/to/p1.config"
  pipeline.workers: 3
- pipeline.id: my-other-pipeline
  path.config: "/etc/different/path/p2.cfg"
  queue.type: persisted
```

Ingestion de données

Beats, exemples FileBeat, MetricBeat
Concepts Logstash
Syntaxe configuration Logstash
Principaux inputs, filtres, outputs
Résilience

Introduction

- Logstash fournit 2 mécanismes pour garantir qu'aucun événement ne sera oublié même en cas d'arrêt brusque ou d'indisponibilité d'une sortie :
 - File persistante : Événements en cours de traitement persistés sur le disque
 - Boite des dead letters : Événements non délivrés persistés sur le disque

Bénéfices des files persistantes

- En fait, les files persistantes apportent 2 bénéfices :
 - Capable d'absorber un pic de charge sans un autre mécanisme de buffering comme Redis ou Kafka
 - Garantie de livraison unique de chaque événement même lors d'un arrêt brutal.

Configuration

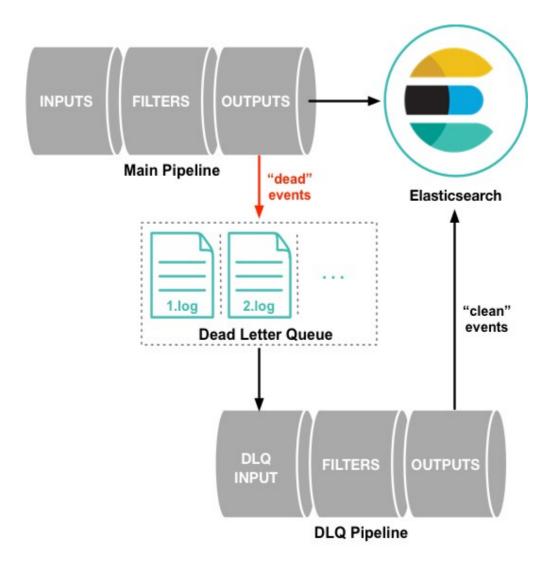
- queue.type: persisted pour autoriser les files persistantes.
- path.queue: Chemin où sont stockés les messages
- queue.page_capacity: La taille maximale d'une page (i.e un fichier de stockage). Par défaut 64mb.
- queue.drain: true => Logstash vide la file avant son arrêt total
- queue.max_events: Le nombre maximum événements dans la file. Par défaut illimité (0)
- queue.max_bytes: La capacité totale de la file. Par défaut 1gb

Bufferisation

- Lorsque la file est pleine, les entrées de logstash sont bloquées et les nouveaux événements ne rentrent pas dans la pipeline
- Cela permet de ne pas surcharger les sorties (elasticsearch)

Dead letter

- Par défaut, lorsque logstash rencontre un événement qui provoque une erreur, l'événement est supprimé.
- Cela peut être évité si l'on configure une dead letter (seulement pour un output elasticsearch)
- L'événement fautif est alors stocké sur disque avec des méta-données additionnelles donnant la cause de l'erreur.
- Pour traiter les événements en erreur, il suffit alors d'utiliser le plugin d'entrée dead_letter_queue



Configuration

```
dead_letter_queue.enable: true
path.dead_letter_queue:
"path/to/data/dead_letter_queue"
dead_letter_queue.max_bytes : 1024mb
```

Pipeline de traitement

```
input {
  dead letter queue {
    path => "/path/to/data/dead letter queue"
    commit offsets => true
    pipeline id => "main"
output {
  stdout {
    codec => rubydebug { metadata => true }
```

Atelier 6.3: Exécution des 2 pipelines

Mapping et types de données

Types de données

Contrôle du mapping
Configuration et création d'index
Gabarits d'index

Types simples supportés

• ELS supporte :

- Les chaînes de caractères : string
 - text ou keyword (pas analysé)
- Les numériques : byte , short , integer , long, float , double, token_count
- Les booléens : boolean
- Les dates : date
- Les octets : binary
- Les intervalles : integer_range, float_range, long_range, double_range, date_range
- Les adresses IP : IPV4 ou IPV6
- Les données de géo-localisation : geo_point, geo_shape
- Un requête (structure JSON) : percolator

Valeur exacte ou full-text

- Les chaînes de caractère indexées par ELS peuvent être de deux types :
 - keyword : La valeur est prise telle quelle, des opérateurs de type <u>filtre</u> peuvent être utilisés lors de la recherche Foo! = foo
 - text: La valeur est analysée et découpée en termes ou token. Des opérateurs de recherche full-text peuvent être utilisés lors des recherche. Cela concerne des données en langage naturelS

Index inversé

- Afin d'accélérer les recherches, ELS utilise une structure de donnée nommée index inversé
- Cela consiste en une liste de mots unique où chaque mot est associé aux documents dans lequel il apparaît.

Exemple

	Α	В
1	term	docs
2	pizza	3, 5
3	solr	2
4	lucene	2, 3
5	sourcesense	2, 4
6	paris	1, 10
7	tomorrow	1, 2, 4, 10
8	caffè	3, 5
9	big	6
10	brown	6
11	fox	6
12	jump	6
13	the	1, 2, 4, 5, 6, 8, 9

Analyseurs

- Les analyseurs utilisés à l'indexation et lors de la recherche, transforment un champ texte en un flux de "token" ou mots qui constituent l'index inversé.
- ELS propose des analyseurs prédéfinis :
 - Analyseur Standard : C'est l'analyseur par défaut. Le meilleur choix lorsque le champ texte est dans des langues diverses. Il consiste à :
 - Séparer le texte en mots
 - Supprimer la ponctuation
 - Passer tous les mots en minuscule
 - Analyseurs de langues : Ce sont des analyseurs spécifiques à la langue. Ils incluent les « stop words » (enlève les mots les plus courant) et extrait la racine d'un mot. C'est le meilleur choix si le champ texte est dans une langue fixe



Test des analyseurs

```
GET /_analyze?analyzer=standard
Text to analyze
<u>Réponse</u>:
"tokens": [ {
  "token": "text",
  "start offset": 0,
  "end offset":4,
  "type": "<ALPHANUM>",
  "position": 1
}, {
  "token": "to",
  "start offset": 5,
  "end_offset": 7,
  "type": "<ALPHANUM>",
  "position": 2
  "token": "analyze",
  "start offset": 8,
  "end offset": 15,
  "type":"<ALPHANUM>",
  "position": 3
} ] }
```



Comportement par défaut

- Lorsque ELS détecte un nouveau champ String dans un type de document, il le configure automatiquement comme 2 champs :
 - 1 champ text utilisant l'analyseur standard.
 - 1 champ keyword
- Si ce n'est pas le comportement voulu, il faut explicitement spécifier le mapping lors de la création de l'index



Types complexes

- En plus des types simples, ELS supporte
 - Les tableaux : Il n'y a pas de mapping spécial pour les tableaux. Chaque champ peut contenir 0, 1 ou n valeurs { "tag": ["search", "nosql"]}
 - Les valeurs d'un tableau doivent être de même type
 - Un champ à *null* est traité comme un tableau vide
 - Les objets : Il s'agit d'une structure de données embarquées dans un champ
 - Les nested : Il s'agit d'un tableau de structures de données embarquées dans un champ. Chaque élément du tableau est stocké séparément

Mapping des objets embarqués

• ELS détecte dynamiquement les champs objets et les mappe comme objet. Chaque champ embarqué est listé sous *properties*

```
{ "ab": {
  "tweet": {
    "properties": {
      "tweet" { "type": "string" }:
      "user": {
        "type": "object",
        "properties": {
           "id": { "type": "string" },
           "age": { "type": "long"},
           "name": {
             "type": "object",
             "properties": {
               "first": { "type": "string" },
               "last": { "type": "string" }
}} } } }
```

Indexation des objets embarqués

 Un document Lucene consiste d'une liste à plat de paires clé/valeurs. Les objets embarqués sont alors convertis comme suit :

```
{
"tweet":[elasticsearch, flexible, very],
"user.id": [@johnsmith],
"user.age": [26],
"user.name.first": [john],
"user.name.last": [smith]
}
```

Attention!

```
"followers": [
{ "age": 35, "name": "Mary White"},
{ "age": 26, "name": "Alex Jones"},
{ "age": 19, "name": "Lisa Smith"}]
Après indexation, cela donne :
"followers.age": [19, 26, 35],
"followers.name": [alex, jones, lisa, smith, mary, white]
=> Lien entre age et nom perdu!
g=age:19 AND name:Mary retourne des résultats
=> Solution les Nested objects
```

Type nested

- Pour garder l'indépendance de chaque objet, il faut déclarer un type nested
- Cela a pour effet de créer des « sous-documents » indépendants et chaque sous-documents peut être recherché indépendamment (Voir nested query)

Mapping et types de données

Types de données

Contrôle du mapping

Configuration et création d'index

Gabarits d'index

Mapping

- ELS est capable de générer dynamiquement le mapping
 - Il devine alors le type des champs

 On peut voir le mapping d'un type de données dans un index par :

GET /gb/_mapping/tweet

Réponse _mapping

```
{ "gb": {
  "mappings": {
      "properties": {
        "date": {
          "type": "date",
         "format": "dateOptionalTime"
        },
         "name": {
          "type": "text"
        },
         "tweet": {
          "type": "text"
         },
         "user_id":
          "type": "long"
```

Mapping

- Un mapping définit pour chaque champ d'un type de document
 - Le type de donnée
 - Si champ est de type text, l'analyseur associé
 - Les méta-données associées

Mapping personnalisé

- Un mapping personnalisé permet (entre autre) de :
 - Spécifier le type d'un champ
 - Faire une distinction entre les champs string de type full-text ou valeur exacte (keyword)
 - Utiliser des analyseurs spécifiques
 - Définir plusieurs types et analyseurs pour le même champ
 - Spécifier des formats de dates personnalisés

– ...

Spécification du mapping

- On peut spécifier le mapping :
 - Lors de la création d'un index
 - Lors de l'ajout d'un nouveau champ dans un index existant
 - => On ne peut pas modifier un champ déjà indexé
 - Le point d'entrée de l'API est _*mapping*

Exemple (création)

```
PUT /gb
  "mappings": {
      "properties" : {
        "tweet" : {
          "type" : "text",
          "analyzer": "english"
        },
        "date" : {
          "type" : "date"
        },
        "name" : {
         "type" : "keyword"
        },
         "user_id" : {
          "type" : "long"
} } }
```

Exemple (Ajout)

```
PUT /gb/ mapping/
  "properties" : {
    "tag" : {
      "type" : "text",
      "index": "not analyzed"
```

Mapping et types de données

Types de données
Contrôle du mapping
Configuration et création d'index
Gabarits d'index

Introduction

- ELS permet de démarrer sans mise en place particulière
- Par contre, pour une mise en production, il est nécessaire de tuner finement les processus d'indexation et de recherche afin de s'adapter à son cas d'utilisation
- La plupart de ces personnalisations concernent les index

Création manuelle de l'index

• Lors de la création, 2 blocs peuvent être configurées :

```
- settings : Principalement répliques et shards
   - mappings : Les types de champs et les analyseurs
PUT /my_index
"settings": { ... any settings ... },
"mappings": {
  "type_one": { ... any mappings ... },
. . .
} }
Il est également possible de désactiver la création automatique
# config/elasticsearch.yml
action.auto create index: false
```

Répliques et shards

- Les 2 principales configuration sont :
 - Le nombre de shards : nombre de shards primaire qu'un index a. La valeur par défaut est 1 . Cette configuration ne peut pas être changée après la création
 - Le **nombre de répliques** : Par défaut 1, cette configuration peut être changé à tout moment

```
PUT /my_temp_index
{
  "settings": {
     "number_of_shards" : 1,
     "number_of_replicas" : 0
} }
```

Champ_source

- ELS stocke la string JSON (compressée) représentant le document dans le champ _source.
- Ce champ apporte plusieurs fonctionnalités :
 - Le document complet est accessible à partir des résultats de recherche
 - Les requêtes de mise à jour partielle sont possibles
 - Si une réindexation est nécessaire, le champ _source peut être utilisé
 - Les valeurs individuelles des champs peuvent être extraites du champ source lors des requêtes GET ou SEARCH
 - Cela facilite le debugging

Configuration de _source

- Si le comportement par défaut n'est pas désirable :
- Il est possible de désactiver le stockage du document source:

```
PUT /my_index
{ "mappings": { "my_type":
{ "_source": { "enabled": false }
} } }
Ou d'affiner les champs à stocker via les attributs excludes,
includes
PUT /my_index
{ "mappings": { "my_type":
{ "_source": { "excludes": ["data", "content"] }
```

 Mais cependant, attention plus de surbrillance dans les recherches full-text

} } }

Champ _all

- Le champ _*all* concaténant tous les champs n'est souvent plus utile lorsque l'on affine son index.
- Pour le désactiver :

Dynamic Mapping

- La détection et l'ajout automatique de nouveau champs est le dynamic mapping
- Les règles d'affectation des types de données peuvent être customisées via 2 moyens :
 - L'activation ou la désactivation du dynamic mapping et les règles de détection de nouveaux types
 - L'édition de gabarits dynamique (dynamic templates) spécifiant les règles de mapping pour les nouveaux champs

La propriété *mappings/_default_* est dépréciée dans la version 6.x

Activation/Désactivation du dynamic mapping

- La propriété *dynamic* permet de spécifier le comportement du *dynamic mapping* :
 - true (défaut) : Chaque nouveau champ est automatiquement ajouté
 - false : Tout nouveau champ est ignoré
 - **strict**: Tout nouveau champ lève une exception
- La spécification de *dynamic* peut s'effectuer sur l'objet racine ou sur une propriété particulière

```
PUT /my_index
{
   "mappings": {
      "my_type": {
        "dynamic": "strict",
        "properties": {
            "title": { "type": "string"},
            "stash": { "type": "object", "dynamic": true }
      }
}}
```

Règles de détection par défaut

Par défaut, en fonction du type JSON, ElasticSearch applique des correspondances :

- *null* : Pas d'ajout de champ
- *true* ou *false* : Champ *boolean*
- **Point flottant**: Champ float
- *integer* : Champ *long*
- *object* : champ *object*
- array : Dépend de la première valeur non nulle du tableau
- String
 - Soit un champ date (Possibilité de configurer les formats de détection)
 - Soit un double ou long (Possibilité de configurer les formats de détection)
 - Soit un champ *text* avec un sous-champ *keyword*.

Exemple : Configuration des formats de détection

```
PUT my index
  "mappings": {
      "dynamic date formats": ["MM/dd/yyyy"]
PUT my index
  "mappings": {
      "numeric detection": true
```

Exemple

```
PUT my index
{ "mappings": {
     "dynamic templates": [
       { "integers": {
           "match_mapping_type": "long",
           "mapping": {
             "type": "integer"
       } } },
       { "strings": {
           "match mapping type": "string",
           "mapping": {
             "type": "text",
             "fields": {
               "raw": {
                 "type": "keyword",
                 "ignore_above": 256
```

Gabarits dynamiques

- Les gabarits d'index définissent en général des gabarits dynamiques
- Il permettent de définir des règles de mapping personnalisées en fonction :
 - Du datatype détecté par ELS avec match_mapping_type.
 - Du nom du champ avec les propriétés match, unmatch ou match_pattern.
 - Du **chemin** complet du champ avec *path_match* et *path_unmatch*.
- Le nom d'origine du champ {name} et le type détecté {dynamic_type} peuvent être utilisés comme variable lors de la spécification des règles

Spécification

- Les gabarits dynamiques sont donc des collections de règles nommées.
- Ils peuvent être associés à un index ou un gabarit d'index
- La syntaxe est la suivante :

Les règles sont traitées dans l'ordre et la première qui match gagne

Exemple

```
PUT my index
{ "mappings": {
     "dynamic templates": [
       { "integers": {
           "match_mapping_type": "long",
           "mapping": {
             "type": "integer"
       } } },
       { "strings": {
           "match mapping type": "string",
           "mapping": {
             "type": "text",
             "fields": {
               "raw": {
                 "type": "keyword",
                 "ignore_above": 256
```

Mapping et types de données

Types de données
Contrôle du mapping
Configuration et création d'index
Gabarits d'index

Introduction

- Les gabarits d'index permettent de définir des gabarits qui s'appliquent lors de la création d'index, lorsque son nom respecte un pattern (propriété indexpattern)
- Ils définissent 2 aspects:
 - settings : Nombre de shards, de répliques, etc
 - mappings : Types des champs

API Rest

 Les gabarits d'index utilise l'API Rest <u>template</u>. Ex :

Exemple pattern logstash

```
"mappings" : {
      "dynamic_templates" : [
          "message_field" : {
           "path_match" : "message",
           "match mapping type" : "string",
           "mapping" : {
             "type" : "text",
             "string_fields" : {
           "match" : "*",
           "match mapping type" : "string",
           "mapping" : {
             "type" : "text",
             "norms" : false,
             "fields" : {
              "keyword" : {
                "type" : "keyword",
                "ignore_above" : 256 } } }
      "properties" : {
        "@timestamp" : {"type" : "date" },
        "@version" : {"type" : "keyword"},
        "geoip" : {
         "dynamic" : true,
         "properties" : {
           "ip" : { "type" : "ip"},
           "location" : { "type" : "geo point" },
           }
```

Recherche avec DSL

Syntaxe DSL

Principaux opérateurs Agrégations Géolocalisation

Introduction DSL

- Les recherches avec un corps de requête offrent plus de fonctionnalités qu'une recherche simple.
- En particulier, elles permettent :
 - De combiner des clauses de requêtes plus facilement
 - D'influencer le score
 - De mettre en surbrillance des parties du résultat
 - D'agréger des sous-ensemble de résultats
 - De retourner des suggestions à l'utilisateur

–

GET ou POST

- La RFC 7231 qui traite de la sémantique HTTP ne définit pas des requêtes GET avec un corps
 - => Seuls certains serveurs HTTP le supportent
- ELS préfère cependant utiliser le verbe GET car cela décrit mieux l'action de récupération de documents
- Cependant, afin que tout type de serveur HTTP puisse être mis en frontal de ELS, les requêtes GET avec un corps peuvent également être effectuées avec le verbe POST

Recherches vides

```
GET /_search
{}
GET /index_2014*/_search
{}
GET /_search
"from": 30,
"size": 10
```

Requête DSL

- Le langage DSL permet d'exposer toute la puissance du moteur Lucene avec une interface JSON
- Pour utiliser DSL, il faut passer une requête dans le paramètre query :

```
GET /_search
{ "query": YOUR_QUERY_HERE }
```

Principe DSL

- DSL peut être vu comme un arbre syntaxique qui contient :
 - Des clauses de requête feuille.
 Elles correspondent à un type de requête (match, term, range)
 s'appliquant à un champ. Elle peuvent s'exécuter seules
 - Des clauses composées.
 Elles combinent d'autres clauses (feuille ou composée) avec des opérateurs logiques (bool, dis_max) ou altèrent leurs comportements (constant_score)
- De plus, les clauses peuvent être utilisées dans 2 contextes différents qui modifient leur comportement
 - Contexte requête ou full-text
 - Contexte filtre

Exemple Combinaison

```
"query" {
    "bool": {
        "must": { "match": { "tweet": "elastic" }},
        "must_not": { "match": { "name": "mary" }},
        "should": { "match": { "tweet": "full text" }}
    }
}
```

Distinction entre requête et filtre

- DSL permet d'exprimer deux types de requête
 - Les filtres sont utilisés pour les champs contenant des valeurs exactes. Leur résultat est de type booléen. Un document satisfait un filtre ou pas
 - Les recherches calculent un score de pertinence pour chaque document trouvé. Le résultat est trié par le score de pertinence

Activation des contextes

- Le contexte requête est activée dés lors qu'une clause est fournie en paramètre au mot-clé *query*
- Le contexte filtre est activée dés lors qu'une clause est fournie en paramètre au mot-clé filter ou must_not

Exemple

Recherche avec DSL

Syntaxe DSL

Principaux opérateurs

Agrégations

Géolocalisation

Opérateurs dans le contexte filtres

```
• term : Utilisé pour filtrer des valeurs exactes :
 { "term": { "age": 26 }}
• terms : Permet de spécifier plusieurs valeurs :
 { "terms": { "tag": [ "search", "full_text", "nosql" ]
 }}
• range : Permet de spécifier un intervalle de date ou nombre :
 { "range": { "age": { "gte": 20, "lt": 30 } } }
• exists et missing : Permet de tester si un document contient ou pas un
 champ
 { "exists": { "field": "title" }}
• bool : Permet de combiner des clauses avec :

    must équivalent à ET

  - must not équivalent à NOT

    should équivalent à OU
```

match

- La recherche *match* est la recherche standard pour effectuer une recherche exacte ou full-text sur presque tous les champs.
 - Si la requête porte sur un champ full-text, il analyse la chaîne de recherche en utilisant le même analyseur que le champ,
 - si la recherche porte sur un champ à valeur exacte, il recherche pour la valeur exacte
- { "match": { "tweet": "About Search" }}

OR par défaut

- match est une requête booléene qui par défaut analyse les mots passés en paramètres et construit une requête de type OR. Elle peut être composée de :
 - **operator** (and/or):
 - minimum_should_match : le nombre de clauses devant matcher
 - analyzer : l'analyseur à utiliser pour la chaîne de recherche
 - *lenient* : Pour ignorer les erreurs de types de données

Exemple

```
GET /_search
    "query": {
        "match" : {
            "message" : {
                "query": "this is a test",
                "operator" : "and"
```

multi_match

• La requête *multi_match* permet d'exécuter la même requête sur plusieurs champs :

```
{"multi_match": { "query": "full text search", "fields": [
"title", "body" ] } }
```

- Les caractères joker peuvent être utilisés pour les champs
- Les champs peuvent être boostés avec la notation ^

```
GET /_search
{
    "query": {
        "multi_match" : {
            "query" : "this is a test",
            "fields" : [ "subject^3", "text*" ]
        }
    }
}
```

Filtre *prefix*

 Le filtre prefix est une recherche s"effectuant sur le terme. Il n'analyse pas la chaîne de recherche et assume que l'on a fourni le préfixe exact

```
GET /my_index/address/_search
{
"query": {
  "prefix": { "postcode": "W1" }
}
```

Wildcard et regexp

 Les recherche wildcard ou regexp sont similaires à prefix mais permet d'utiliser des caractère joker ou des expressions régulières

```
GET /my_index/address/_search
{
  "query": {
    "wildcard": { "postcode": "W?F*HW" }
}
GET /my_index/address/_search
{
  "query": {
  "regexp": { "postcode": "W[0-9].+" }
}
}
```

match_phrase

 La recherche *match_phrase* analyse la chaîne pour produire une liste de termes mais ne garde que les documents qui contient tous les termes dans le même position.

```
GET /my_index/my_type/_search
{
  "query": {
    "match_phrase": { "title": "quick brown fox" }
}}
```

Proximité avec slop

- Il est possible d'introduire de la flexibilité au phrase matching en utilisant le paramètre **slop** qui indique à quelle distance les termes peuvent se trouver.
- Cependant, les documents ayant ces termes les plus rapprochés auront une meilleur pertinence.

```
GET /my_index/my_type/_search
{
"query": {
   "match_phrase": {
    "title": {
        "query": "quick fox",
        "slop": 20 // ~ distance en mots
}    } }
}
```

match_phrase_prefix

- La recherche match_phrase_prefix se comporte comme match_phrase, sauf qu'il traite le dernier mot comme un préfixe
- Il est possible de limiter le nombre d'expansions en positionnant max_expansions

```
"match_phrase_prefix" : {
  "brand" : {
     "query": "johnnie walker bl",
     "max_expansions": 50
}
}
```

Requête fuzzy

- La recherche fuzzy ou recherche floue permet de gérer des erreurs de typo en récupérant les termes approchant (Distance de Levenshtein)
- Elle est équivalente à une recherche par terme

```
GET /my_index/my_type/_search
{
  "query": {
    "fuzzy": {"text": "surprize" }
} }
```

2 paramètres peuvent être utilisées pour limiter l'impact de performance :

- prefix_length : Le nombre de caractères initiaux qui ne seront pas modifiés.
- max_expansions : Limiter les options que la recherche floue génère. La recherche fuzzy arrête de rassembler les termes proches quand elle atteint cette limite

Recherche avec DSL

Syntaxe DSL
Principaux opérateurs
Agrégations
Géolocalisation

Introduction

- Les agrégations sont extrêmement puissantes pour le reporting et les tableaux de bord
- Des énormes volumes de données peuvent être visualisées en temps-réel
 - Le reporting change au fur et à mesure que les données changent
- L'utilisation de la stack Elastic, Logstash et Kibana démontre bien tout ce que l'on peut faire avec les agrégations.

Exemple (Kibana)



Syntaxe DSL

- Une agrégation peut être vue comme une unité de travail qui construit des informations analytiques sur une ensemble de documents.
- En fonction de son positionnement dans l'arbre DSL, il s'applique sur l'ensemble des résultats de la recherche ou sur des sous-ensembles
- Dans la syntaxe DSL, un bloc d'agrégation utilise le mot-clé aggs

```
// Le max du champ price dans tous les documents
POST /sales/_search?size=0
{
    "aggs" : {
        "max_price" : { "max" : { "field" : "price" } }
}
```

Types d'agrégations

- Plusieurs concepts sont relatifs aux agrégations :
 - Groupe ou Buckets: Ensemble de document qui ont un champ à la même valeur ou partagent un même critère.
 Les groupes peuvent être imbriqués. ELS propose des syntaxes pour définir les groupes et compter le nombre de documents dans chaque catégorie
 - Métriques : Calculs de métriques sur un groupe de documents (min, max, avg, ..)
 - Matrice : Opérations de classification selon différents champs, produisant une matrice des différentes possibilités. Le scripting n'est pas supporté pour ce type d'agrégation
 - Pipeline : Une agrégation s'effectuant sur le résultat d'une agrégation

Exemple Bucket

```
GET /cars/transactions/_search
{
"aggs" : {
"colors" : {
    "terms" : { "field" : "color.keyword" }
} } }
```

Réponse

```
"hits": { "hits": [] },
"aggregations": {
"colors": {
  "doc_count_error_upper_bound": 0, // incertitude
  "sum_other_doc_count": 0,
  "buckets": [
    { "key": "red", "doc_count": 4 },
    { "key": "blue", "doc_count": 2 },
    { "key": "green", "doc_count": 2 }
} } }
```

Exemple métrique

```
GET /cars/transactions/_search
{
    "size": 0,
    "aggs" : {
        "avg_price" : {
            "avg" : {"field" : "price"}
        }
    }
}
```

Réponse

```
"hits": {
    "total": 8,
    "max_score": 0,
    "hits": []
  "aggregations": {
    "avg_price": {
      "value": 26500
```

Juxtaposition Bucket/Métriques

```
GET /cars/transactions/ search
  "size": 0,
  "aggs" : {
        "colors" : {
            "terms" : { "field" :
"color.keyword" }
        "avg price" : {
            "avg" : {"field" : "price"}
```

Réponse

```
"hits": { "hits": [] },
"aggregations": {
   "avg price": {
      "value": 26500
   },
    "colors": {
      "doc_count_error_upper_bound": 0,
      "sum other doc count": 0,
      "buckets": [
       { "key": "red", "doc count": 4 },
        { "key": "blue", "doc_count": 2 },
        { "key": "green", "doc_count": 2 }
   }
 }}
```

Imbrication

```
GET /cars/transactions/ search {
"aggs": {
  "colors": {
    "terms": { "field": "color" },
    "aggs": {
      "avg price": {
        "avg": { "field": "price"}
      }, "make": {
        "terms": { "field": "make" }
```

Réponse

```
{
"aggregations": {
  "colors": {
    "buckets": [
      { "key": "red",
         "doc_count": 4,
         avg_price": {
            "value": 32500
          },
         "make": { "buckets": [
                            { "key": "honda", "doc_count": 3 },
                            { "key": "bmw", "doc_count": 1 }
         }
     },
```

Agrégation et recherche

 En général, une agrégation est combinée avec une recherche. Les buckets sont alors déduits des seuls documents qui matchent.

```
GET /cars/transactions/_search
{
   "query" : {
       "match" : { "make" : "ford" }
}, "aggs" : {
       "colors" : {
       "terms" : { "field" : "color" }
} } }
```

Spécification du tri

```
GET /cars/transactions/ search
"aggs" : {
  "colors" : {
    "terms" : { "field" : "color",
               "order": { "avg_price" : "asc" }
     }, "aggs": {
        "avg price": {
          "avg": {"field": "price"}
} } } }
```

Types de bucket

- Différents types de regroupement sont proposés par ELS
 - Par terme, par filtre : Nécessite une tokenization du champ
 - Par intervalle de valeurs
 - Par intervalle de dates, par histogramme
 - Par intervalle d'IP
 - Par absence d'un champ
 - Par le document parent
 - Significant terms
 - Par géo-localisation

• ...

Intervalle de valeur

```
GET /cars/transactions/_search
{
"aggs":{
  "price":{
    "histogram":{
      "field": "price",
      "interval": 20000
   },
   "aggs":{
     "revenue": {
     "sum": { "field" : "price" }
```

Histogramme de date

```
GET /cars/transactions/ search
"aggs": {
  "sales": {
    "date histogram": {
      "field": "sold",
      "interval": "month",
      "format": "yyyy-MM-dd"
} } }
```

significant_terms

- L'agrégation significant_terms est plus subtile mais peut donner des résultats intéressants (proche du machine-learning).
- Cela consiste à analyser les données retournées et trouver les termes qui apparaissent à une fréquence anormalement supérieure Anormalement signifie : par rapport à la fréquence pour l'ensemble des documents => Ces anomalies statistiques révèlent en général des choses intéressantes

Fonctionnement

- significant_terms part d'un résultats d'une recherche et effectue une autre recherche agrégé
- Il part ensuite de l'ensemble des documents et effectue la même recherche agrégé
- Il compare ensuite les résultats de la première recherche qui sont anormalement pertinent par rapport à la recherche globale
- Avec ce type de fonctionnement, on peut :
 - Les personnes qui ont aimé ... ont également aimé ...
 - Les clients qui ont eu des transactions CB douteuses sont tous allés chez tel commerçant
 - Tous les jeudi soirs, la page untelle est beaucoup plus consultée

- ...

Exemple

```
{
    "query" : {
        "terms" : {"force" : [ "British Transport Police" ]}
    },
    "aggs" : {
        "significantCrimeTypes" : {
            "significant_terms" : { "field" : "crime_type" }
        }
    }
}
```

Réponse

=> Le taux de vols de vélos est anormalement élevé pour « British Transport Police »

Types de métriques

- ELS propose de nombreux métriques :
 - avg,min, max, sum
 - value_count, cardinality : Comptage de valeur distinctes
 - top_hit : Les meilleurs documents
 - extended_stats: Fournit plein de métriques (count, sum, variance, ...)
 - percentiles : percentiles

Recherche avec DSL

Syntaxe DSL
Principaux opérateurs
Agrégations
Géolocalisation

Introduction

- ELS permet de combiner la géo-localisation avec les recherches full-text, structurées et les agrégations
- ELS a 2 modèles pour représenter des données de géolocalisation
 - Le type geo_point qui représente un couple latitudelongitude. Cela permet principalement le calcul de distance
 - Le type geo_shape qui définit une zone via le format GeoJSON. Cela permet de savoir si 2 zones ont une intersection

Geo-point

• Les Geo-points ne peuvent pas être détectés automatiquement par le *dynamic mapping*. Ils doivent être explicitement spécifiés dans le mapping:

Filtres

- 4 filtres peuvent être utilisés pour inclure ou exclure des documents vis à vis de leur geo-point
 :
 - geo_bounding_box : Les geo-points inclus dans le rectangle fourni
 - geo_distance : Distance d'un point central inférieur à une limite. Le tri et le score peuvent être relatif à la distance
 - geo_distance_range : Distance dans un intervalle
 - geo_polygon : Les geo-points incluent dans un polygone

Exemple

Agrégation

- 3 types d'agrégation sur les geo-points sont possibles
 - geo_distance (bucket): Groupe les documents dans des ronds concentriques autour d'un point central
 - geohash_grid (bucket): Groupe les documents par cellules (geohash_cell, les carrés de google maps) pour affichage sur une map
 - geo_bounds (metrics): retourne les coordonnées d'une zone rectangle qui engloberait tous les geopoints. Utile pour choisir le bon niveau de zoom

Exemple

```
GET /attractions/restaurant/_search
"query": { "bool": { "must": {
  "match": { "name": "pizza" }
  "filter": {    "geo_bounding_box": {
       "location": { "top_left": { "lat": 40,8, "lon": -74.1 },
                      "bottom right": {"lat": 40.4, "lon": -73.7 }
} } } },
  "aggs": {
    "per ring": {
      "geo_distance": {
        "field": "location",
        "unit": "km",
        "origin": {
          "lat": 40.712,
          "lon": -73.988
         },
          "ranges": [
             { "from": 0, "to": 1 },
             { "from": 1, "to": 2 }
} } }
```

Geo-shape

• Comme les champs de type *geo_point* , les *geo-shape* doivent être mappés explicitement : PUT /attractions "mappings": { "landmark": { "properties": { "name": { "type": "string" }, "location": { "type": "geo shape" } PUT /attractions/landmark/dam square "name" : "Dam Square, Amsterdam", "location" : { "type" : "polygon", "coordinates": [[[4.89218, 52.37356], [4.89205, 52.37276], [4.89301, 52.37274],[4.89392, 52.37250], [4.89218, 52.37356]] } }

Exemple

```
GET /attractions/landmark/ search
"query": {
  "geo shape": {
   "location": {
    "shape": {
     "type": "circle",
     "radius": "1km"
     "coordinates": [ 4.89994, 52.37815]
```

Analyse temps-réel avec Kibana

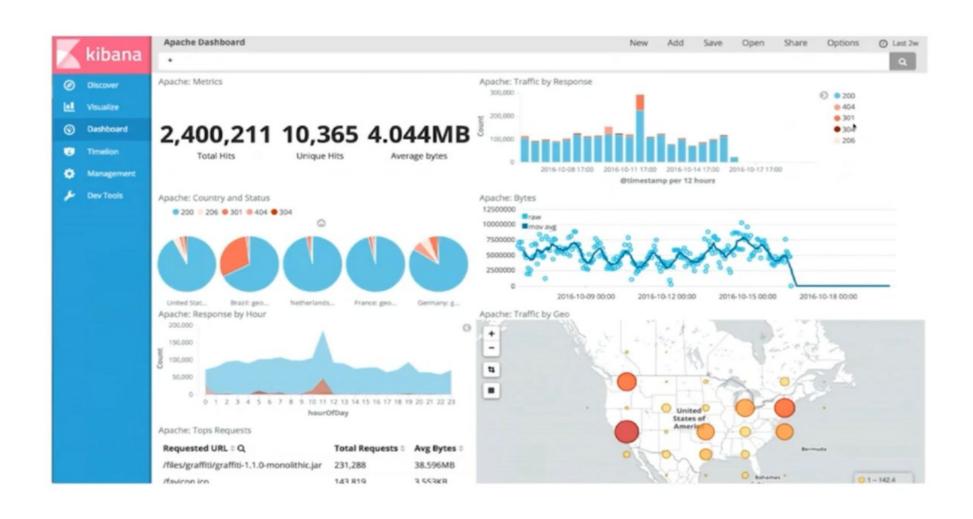
Introduction

Mise au point de tableau de bord Types de visualisation Management

Introduction

- Kibana est une plateforme d'analyse et de visualisation fonctionnant avec ElasticSearch
- Il est capable de rechercher les données stockées dans les index d'ElasticSearch
- Il propose une interface web permettant de créer des tableaux de bord dynamiques affichant le résultat des requêtes en temps réel
- Il s'exécute sur Node.js

Dashboard Kibana



Usages

- Kibana à des destinations de tous profils : Métier, Exploitation, Développeur
- Une fois les données ingérées dans des index ElasticSearch, il permet :
 - D'explorer les données afin de mieux les comprendre
 - Créer des visualisation et les inclure dans des tableaux de bord
 - Créer des présentations afin d'animer des réunions
 - Partager via mail, page web ou documents PDF
 - Appliquer des modèles de Machine Learning pour détecter des anomalies ou anticiper le futur
 - Générer des graphes visualisation les relations entre vos données
 - Gérer les index ElasticSearch
 - Générer des alertes relatives à vos données
 - Organiser les assets Kibana en « Espace » liè au modèle de sécurité et de permissions d'ES

Surveillance, Analyse et réaction aux évènements

- Surveillez les services et les applications en temps réel en collectant des informations sur les performances : APM
- Surveillez la disponibilité de vos sites et services :
 Uptime
- Recherchez, filtrez et suivez tous vos journaux :
 Logs
- Analysez les métriques de votre infrastructure, de vos applications et de vos services : Metrics

Prévenir, détecter et répondre aux menaces

- Créez et gérez des règles pour les événements sources suspects et affichez les alertes créées par ces règles. Detections
- Affichez tous les hôtes et les événements de sécurité liés à un hôte.
 Hosts
- Affichez les principales mesures d'activité du réseau via une carte interactive. Network
- Enquêtez sur les alertes et les menaces complexes, telles que le mouvement latéral de logiciels malveillants entre les hôtes de votre réseau. Timelines
- Créer et suivre les problèmes de sécurité. Cases
- Afficher et gérer les hôtes qui offre des points d'accès sécurisés.
 Administration

Analysez et visualisez vos données

- Connaître ses données. Discover
- Créer des graphiques et d'autres visualisations. Dashboard
- Afficher vos données sous différents angles. Dashboard
- Travailler avec des données de localisation. *Maps*
- Créer une présentation de vos données. Canvas
- Générez des modèles pour le comportement de vos données. Machine Learning
- Explorer les connexions entre vos données. Graph
- Partager vos données. Dashboard, Canvas

Administrer ElasticStack

- Gérer les données ElasticSearch.
 Stack Management > Data
- Mettre en place des règles.
 Stack Management > Rules and Connectors
- Organiser l'espace de travail et les utilisateurs.
 Stack Management > Spaces
- Définir les rôles et pemissions.
 Stack Management > Users
- Personnaliser Kibana.
 Stack Management > Advanced Settings

Analyse temps-réel avec Kibana

Introduction

Mise au point de tableau de bord

Types de visualisation

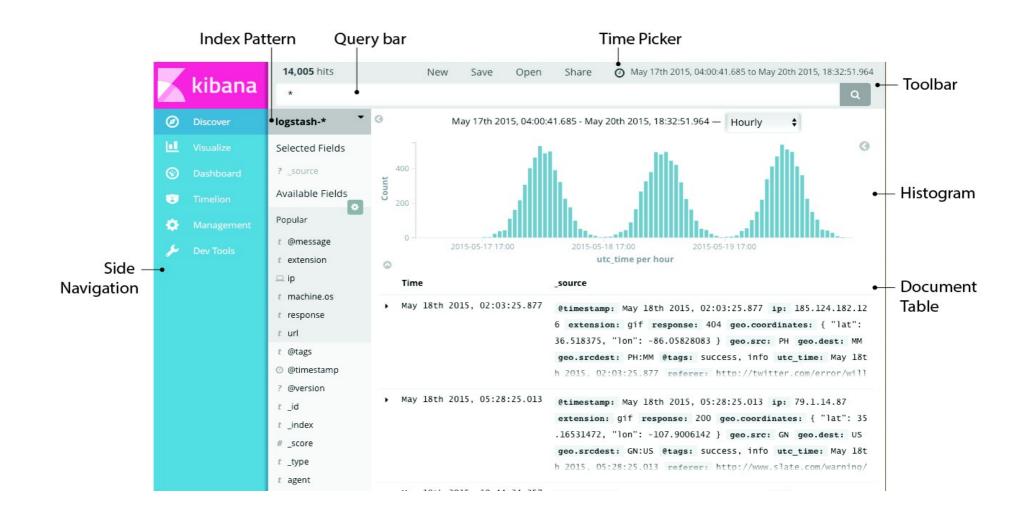
Management

Etapes de mise au point d'un tableau de bord

- Définir un Index Pattern et son champ d'horodatage
- Explorer les données et éventuellement enregistrer des requêtes
- Créer des visualisations, agrégations, temps, maps
- Les disposer sur un tableau de bord
- Partager l'URL associé au tableau de bord

Création d'index pattern

- Pour exploiter des données, il faut définir des gabarits d'index, i.e. collection d'index respectant une règle de nommage :
 - ex : logstash-*
 - Il faut également indiquer le champ timestamp de ces index
- A la définition, Kibana charge les informations de mapping de ces index et indique de façon claire leur type, si ils peut servir pour la recherche ou pour une agrégation.
- Kibana permet également de définir des colonnes calculées à partir d'expressions de script



Fenêtre temporelle

- Si un champ timestamp existe dans l'index :
 - Le haut de page affiche la distribution des documents sur une période (par défaut 15 mn)
 - La fenêtre de temps peut être changée
- Cette fenêtre temporelle est présente dans la majorité des pages de Kibana

Recherche

- Les critères de recherche peuvent être saisis dans la barre de requête. Il peut s'agir de :
 - Un simple texte
 - Une requête Lucene
 - Une requête DSL avec JSON.
- Le résultat met à jour l'ensemble de la page et seuls les 500 premiers documents sont retournés dans l'ordre chronologique inverse
- Des filtres sur les champs peuvent être spécifiés
- La recherche peut être sauvegardée
- L'index pattern peut être modifié
- La recherche peut se rafraîchir automatiquement toutes les X temps

Gestion des filtres

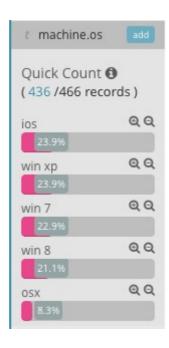
- Plusieurs boutons sont disponibles sur les filtres :
 - Activation désactivation
 - Pin : Le filtre est conservé même lors d'un changement de contexte
 - Toggle : Filtre positif ou négatif
 - Suppression
 - Edition : On peut alors travailler avec la syntaxe DSL et créer des combinaisons de filtre

Visualisation des documents

- La liste affiche par défaut 500 documents (propriété *discover:sampleSize*)
- Il est possible de chosir le critère de tri
- Ajouter/Supprimer des champs
- Des statistiques sont également disponibles

Statistiques sur la valeur des champs

 Des statistiques sur la valeur des champs permettent de savoir combien de documents ont une valeur particulière dans un champ



Visualisation

- Les visualisations sont basées sur des recherches ES
- En utilisant des agrégations, on peut créer des graphiques qui montrent des tendances, des pics, ...
- Les visualisations peuvent ensuite être composées en tableau de bord
- Différents éditeurs pour les visualisations :
 - Lens: Drag and Drop
 - Maps : Géolocalisation
 - TSVB : Adaptées aux séries temporelles
 - Visualisations personnalisées : Vega
 - Visualisations basées sur des agrégations
 - Timelion : Séries temporelles avec un langage d'expression

Agrégations

- *Area* : Visualise les contributions totales de plusieurs séries
- Table de données : Affichage en tableau des données agrégées
- *Line* : Compare différente séries
- Metric: Affichage d'un seul métrique
- Gauge/Goal: Une unique valeur avec des intervalles de bonnes/mauvaises valeurs ou par rapport à un objectif
- **Pie**: Camembert.
- Heat map : Tableau coloré
- Nuage de tags : Les tags les plus important ont la plus grande police
- Horizontal / Vertical bar : Histogramme permettant la comparaison de séries

Étapes de création

- Les étapes de création de l'éditeur classique consistent donc à :
 - 1. Choisir un type de graphique
 - 2. Spécifier les critères de recherche ou utiliser une recherche sauvegardée
 - 3. Choisir le calcul d'agrégation pour l'axe des Y (count, average, sum, min, ...)
 - 4. Choisir le critère de regroupement des données (bucket expression) (Histogramme de date, Intervalle, Termes, Filtres, Significant terms, ...)
 - 5. Définir éventuellement des sous-agrégations
- Lens permet de créer sa visualisation plus intuitivement via Drag
 & Drop

Bucket expressions

- Histogramme Date : Un histogramme de date est construit sur un champ entier pour lequel on a précisé une fenêtre temporel
- Intervalle : Entier, date ou IPV4
- Terme : Permet de présente les n meilleurs (ou plus basse) pertinence ordonné par la valeur agrégée
- Filtres: Il est possible d'ajouter des filtres de données à ce niveau
- Significant Terms : Agrégation significant terms
- Geohash : Agrégation sur les coordonnées géographiques (Data Table et carte)

Options

- Lors de plusieurs agrégations en Y, il est possible de spécifier leur mode d'affichage
 - **Stacked**: Empile les agrégations les unes sur les autres.
 - *Overlap*: Superposition avec transparence
 - Wiggle : Ombrage
 - Percentage : Chaque agrégation comme une portion du total
 - Silhouette : Chaque agrégation comme variance d'une ligne centrale
 - Grouped : Groupe les résultats horizontalement par les sousagrégations (Grapique barre) .

Séries multiples : TSVB

- TSVB permet de dessiner plusieurs séries sur le même graphique
- Il nécessite :
 - Un champ date
 - Des métriques numériques pouvant être agrégés

Maps

- Possibilité de définir différentes couches sur la carte
 - Zone ombragées (les pays par exemple) en fonction des données
 - Points sur la carte en fonction de documents ES
 - Lignes, polygones
 - Les Top données (Par exemple, les coordonées GPS les plus récentes) de documents ES
 - Agrégations via une grille. Heat Map ou Cluster
 - Custom via le format GeoJSON
- Affichage de la couche selon le niveau de zoom

Tableau de bord

- Un tableau de bord affiche un ensemble de visualisations sauvegardées
- Il est possible de réarranger et retailler les visualisations
- Il est possible de partager les tableaux de bord par un simple lien

TP10: Prise en main Kibana

Vega

- Vega et Vega-Lite sont deux grammaires permettant de créer des visualisations personnalisées.
- Il est nécessaire d'écrire des requêtes Elasticsearch manuellement.
- Vega et Vega-Lite utilise JSON

Timelion

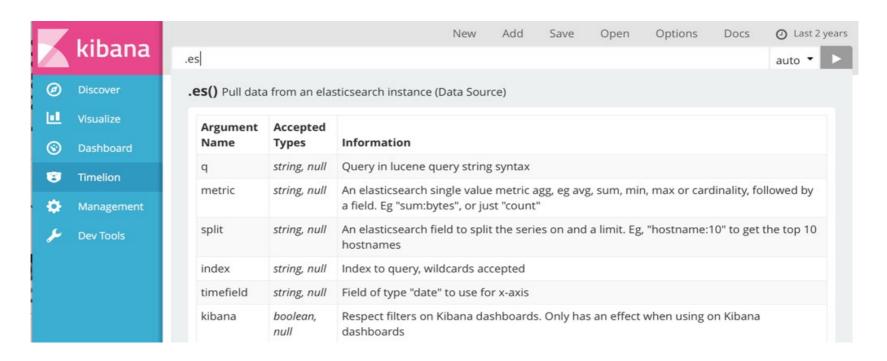
- Timelion est un visualiseur dédié aux données temporelles qui permet de combiner des sources de données complètement indépendantes dans le même graphique.
- Il est piloté par un langage d'expression simple permettant de récupérer les données et d'effectuer des calculs.
- Avec timelion, il est possible de répondre à ce type de question :
 - Quel est le pourcentage de la population japonaise qui a visité mon site ?

Éléments de syntaxe

- L'interface de timelion consiste en :
 - Une zone de saisie d'expression
 - Une zone de visualisation
- Chaque expression timelion démarre avec une fonction identifiant une source de données. Pour ElasticSearch : es (*)
- 2 sources de données peuvent être dessinées côte à côte en utilisant la virgule (,) ;.
 .es(*),.es(metric=cardinality:user)
- Elles peuvent être combinées via des fonctions :
 .es(*).divide(es(metric=cardinality:user))
- D'autres sources de données peuvent être utilisées (Worldbank's Data API par exemple)
 - .wbi(MZ) // Population du Mozambique

Aide en ligne et documentation

- La documentation fait partie de timelion
- Elle est disponible par le lien Docs
- De plus, la complétion est très efficace



Exemples

```
    # Affichage en temps réel de la moyenne du

• # pourcentage d'utilisation CPU user à partir
• # d'un index metricbeats d'elastic search

    .es(index=metricbeat-*, timefield='@timestamp',

  metric='avg:system.cpu.user.pct')

    # La même chose en ajoutant une série affichant

• # les données pour un offset d'1h
• .es(index=metricbeat-*, timefield='@timestamp',
  metric='avg:system.cpu.user.pct'), .es(offset=-
  1h,index=metricbeat-*, timefield='@timestamp',
  metric='avg:system.cpu.user.pct')
```

Analyse temps-réel avec Kibana

Introduction
Mise au point de tableau de bord
Types de visualisation
Management

Introduction

- Le menu stack management permet les principales opérations d'exploitation de la stack
 - Gestion des index
 - Du cluster
 - Licences
 - Configuration des interfaces utilisateur : index patterns, spaces, utilisateurs et permissions

Ingestion de données

- Gestion des pipelines Elastic Search
- Gestion centralisée des pipelines logstash (License X-Pack payante)
- Gestion centralisée des beats (En cours de remplacement)

Gestion des données

- Gestion des index (settings, mapping, statistiques, gestion des caches)
- Gestion des stratégies de cycle de vie
- Snapshot et restauration
- Jobs de remplacement, agréger de vielles données et les stocker dans un index plus compact
- Jobs de transformation
- Réplication cross-cluster

Alertes

- Watcher : Définition d'alertes sur les données [X-Pack]
- Gestion centralisée des :
 - Règles (Surveillance de métriques)
 - et connecteurs (Routage des actions)[X-Pack]
- Reporting : Génération périodique de rapport [X-Pack]
- Processus de Machine Learning [X-Pack]

Sécurité

- Gestion des utilisateurs, intégration à des annuaires externes
- Gestion des rôles
- Clés d'API
- Mapping de rôles si intégration à un annuaire externe

Kibana

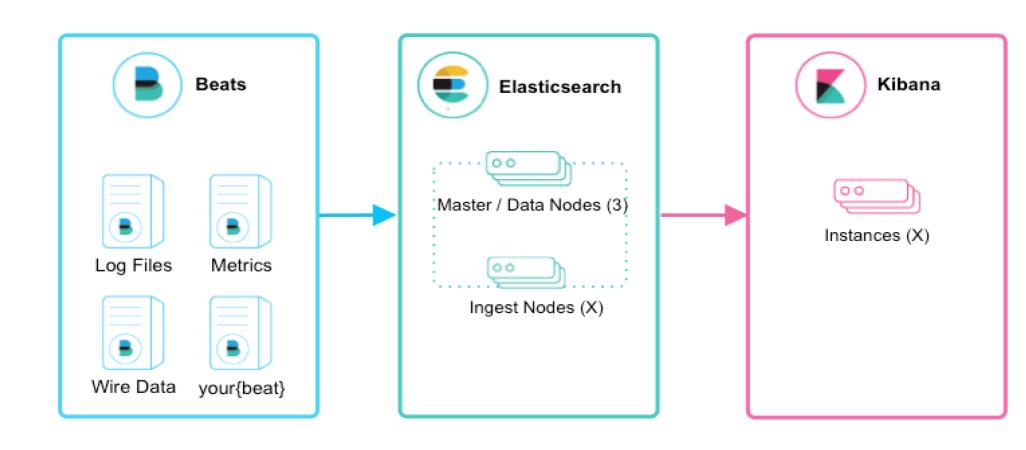
- Gestion des index pattern et de leurs champs
- Gestion des objets sauvegardés, exportation/importation, gestion des tags associés
- Sessions de recherches, permet de définir des groupes de requêtes (qui prennent du temps) qui s'exécutent en tâche de fond
- Les espaces

Déploiement en production

Architectures ingestion

Monitoring Logstash
Architecture Indexation/Recherche
Cycle de vie des index, Gestion des shards
Monitoring ES
Exploitation

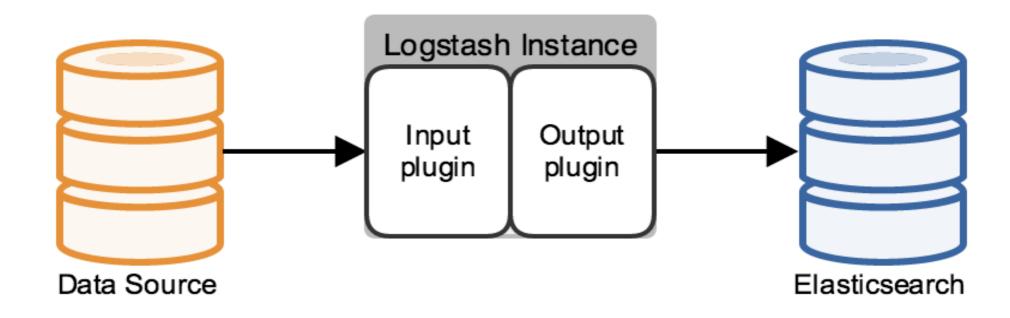
Architecture sans logstash



Apports de logstash

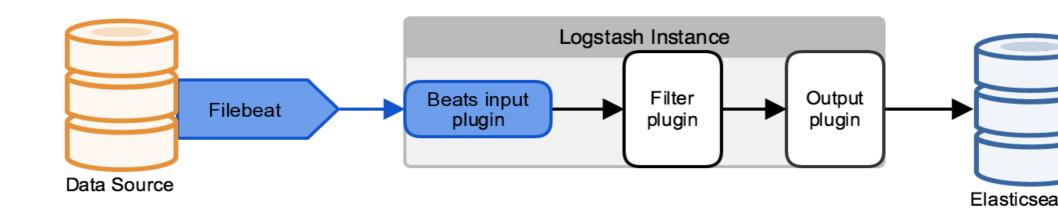
- S'adapter à des pics de charge, via le système de bufferisation intrinsèque de Logstash
- Ingérer des données provenant d'autres sources de données : BD, S3, ou files de message
- Émettre des données vers plusieurs destinations :
 S3, HDFS ou fichier
- Insérer de la logique conditionnelle dans le traitement des événements

Architecture minimale

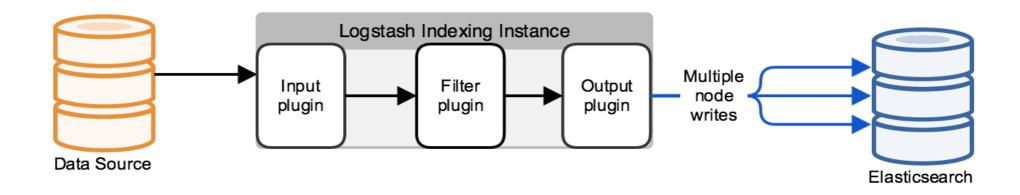


Architecture avec un Beat

 L'utilisation d'un Beat permet de déporter du traitement sur la machine source



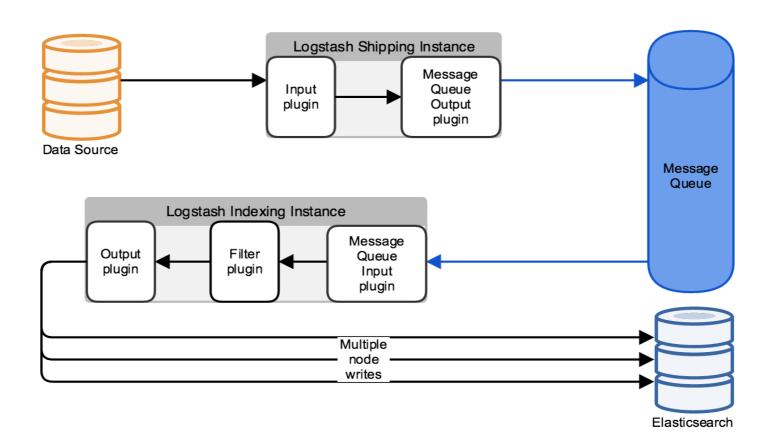
Load balancing sur les noeuds de ElasticSearch



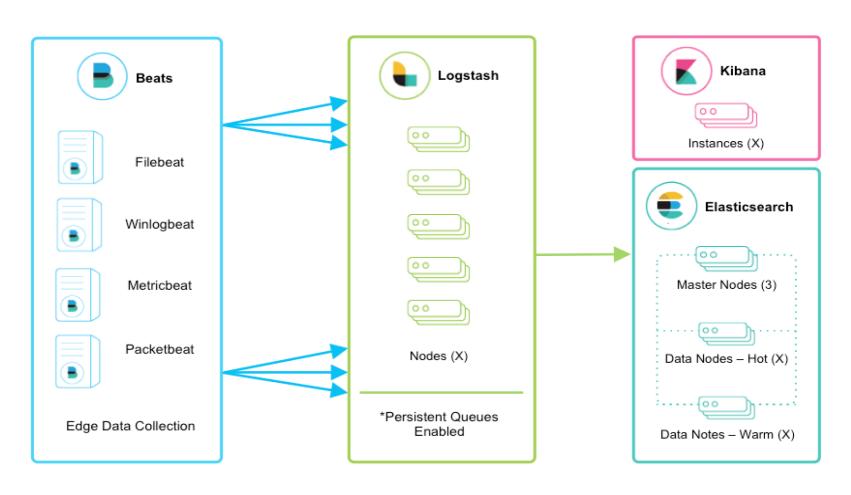
Message broker

- Afin de faire face à des pics de débit, l'architecture peut inclure des message brokers (Redis, Kafka, RabbitMQ).
 - Cela peut soulager le travail d'indexation d'ElasticSearch
- Des instances de logstash écrivent vers une file de message
- D'autres lisent de la file, effectue les traitements et envoient vers ElasticSearch

Message broker



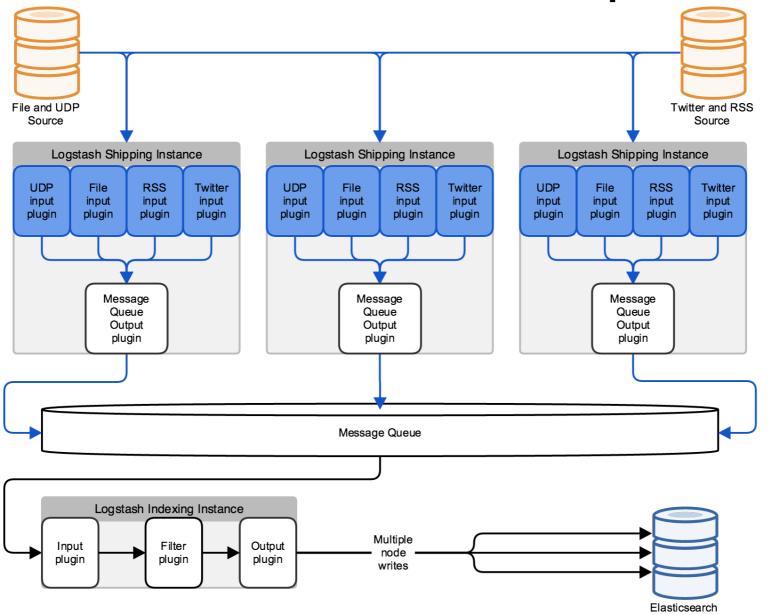
Répartir la charge sur plusieurs Logstash



Caractéristiques

- **Scalabilté** : plusieurs instances de logstash exécutent la même pipeline, des nœuds peuvent être ajoutés, les beats doivent distribuer la charge sur le cluster
- At-least-one: les plugins Filebeat et Winlogbeat le garantissent, les autres non
- **Persistent-queue** : Par défaut, logstash utilise des files mémoire pour le traitement batch des événements ; utiliser des persistent-queue pour éviter des pertes de données en cas de crash
- **Secure transport** : X-Pack
- Monitoring: UI inclut dans X-Pack mais libre d'utilisation, API

Haute disponibilité via des connections multiples



Architecture en tiers

- Un déploiement Logstash a typiquement un pipeline composé de différents tiers :
 - Le tiers d'entrée consomme les données des sources et est composé d'instance logstash avec les bons plugins d'entrée
 - Le broker de messages sert de buffer et de protection contre des pannes
 - Le tiers de filtrage traite et normalise les données
 - Le tiers d'indexation déplace les données traitées vers ElasticSearch
- Chaque tiers peut être scalés selon les besoins

Déploiement en production

Architectures ingestion

Monitoring Logstash

Architecture Indexation/Recherche

Cycle de vie des index, Gestion des shards

Monitoring ES

Exploitation

Introduction

- Logstash fournit une API REST pour la surveillance
- L'API est divisé en 4 domaines
 - Node Info: Informations de configuration d'un nœud
 - Plugins : Les plugins installés
 - Node stats : Métriques sur les nœuds
 - Hot threads: Threads avec un gros usage CPU
- Les réponses JSON peuvent être formattés par les paramètres :
 - pretty=true
 - human=true

Node info

• Sur une pipeline, le nombre de workers, la taille et le délai de batch

```
GET /_node/pipelines
```

Sur l'OS, les versions et les processeurs disponibles

```
GET /_node/os
```

Sur la JVM, processus, Heap et garbage collector
 GET / node/jvm

Plugins info

```
GET /_node/plugins
  "total": 91,
  "plugins": [
      "name": "logstash-codec-collectd",
      "version": "3.0.2"
    },
      "name": "logstash-codec-dots",
      "version": "3.0.2"
    },
```

Node stats

GET /_node/stats/<types>

- Soit tous les métriques, soit limité à un type qui peut être :
 - jvm : JVM stats, threads, usage mémoire et garbage collectors.
 - process : processus, descripteurs de fichiers, consommation mémoire et usage CPU
 - *mem* : Usage mémoire .
 - *pipelines* : Métrique sur la pipeline Logstash

Exemple pipeline

```
"pipeline": {
  "events": { "duration in millis": 7863504, "in": 100, "filtered": 100, "out": 100 },
  "plugins": {
    "inputs": [],
    "filters": [
        "id": "grok 20e5cb7f7c9e712ef9750edf94aefb465e3e361b-2",
        "events": { "duration in millis": 48, "in": 100, "out": 100 },
        "matches": 100,
        "patterns per field": { "message": 1 },
        "name": "grok"
     },
        "id": "geoip 20e5cb7f7c9e712ef9750edf94aefb465e3e361b-3",
        "events": { "duration in millis": 141, "in": 100, "out": 100 },
        "name": "geoip"
    ],
    "outputs": [
        "id": "20e5cb7f7c9e712ef9750edf94aefb465e3e361b-4",
        "events": { "in": 100, "out": 100 },
        "name": "elasticsearch"
  "reloads": {"last_error": null, "successes": 0, "last_success_timestamp": null, "last_failure_timestamp": null, "failures": 0 }
```

Hot Threads

```
GET /_node/hot_threads
```

- Retourne des informations sur les threads qui prennent le plus de CPU
- Pour chaque thread :
 - Le pourcentage de CPU
 - Son état
 - Sa stack trace

Déploiement en production

Architectures ingestion
Monitoring Logstash
Architecture Indexation/Recherche
Cycle de vie des index, Gestion des shards
Monitoring ES
Exploitation

Matériel

- RAM : Le talon d'Achille de ELS. Une machine avec 64 GB est idéale ; 32 GB et 16 GB sont corrects
- **CPU** : Favoriser le nombre de coeur plutôt que la rapidité du CPU
- Disques : Si possible rapides, SSDs ?
 Éviter NAS (network-attached storage)

JVM

- Utiliser la version embarquée de la distribution
- Surtout ne pas modifier la configuration de la JVM fournie par ELS. Elle est issue de l'expérience

Gestion de configuration

 Utiliser de préférence des outils de gestion de configuration comme Puppet, Chef, Ansible ...

=> Sinon la configuration d'un cluster avec beaucoup de nœuds devient rapidement un enfer

Personnalisation d'une configuration

- La configuration par défaut défini déjà beaucoup de choses correctement, Il y a donc peu à personnaliser. Cela se passe dans le fichier *elasticsearch.yml*
 - Le nom du cluster (le changer de elasticsearch) cluster.name: elasticsearch production
 - Le nom des nœuds
 node.name: elasticsearch_005_data
 - Les chemins (hors du répertoire d'installation de préférence)
 path.data: /path/to/data1,/path/to/data2
 # Path to log files:
 path.logs: /path/to/logs
 # Path to where plugins are installed:
 path.plugins: /path/to/plugins

Spécialisation des nœuds

- Tous les nœuds d'un cluster se connaissent mutuellement et peuvent rediriger des requêtes HTTP vers le nœud approprié. Il est possible de spécialiser les nœuds afin de répartir la puissance entre la charge de gestion des données et la charge d'ingestion.
- Les différents types de nœuds sont :
 - Nœuds pouvant être **maître** : **node.master** à true
 - Nœuds de données : node.data à true. Détient les données et effectue les tâches d'indexation et de recherche
 - Nœuds **d'ingestion** : *node.ingest* à *true*. Exécute les pipelines d'ingestion
 - Nœuds de coordination : Nœuds acceptant les requêtes et redirigeant vers les nœuds appropriés
 - Nœuds tribe ou cross-cluster (Version 6.x). Propriétés tribe.* Nœuds pouvant effectuer des recherches vers plusieurs cluster.

Nœuds maître

- Le nœud maître est responsable d'opérations légères :
 - Création ou suppression d'index
 - Surveillance des nœuds du cluster
 - Allocations des shards
- Dans un environnement de production, il est important de s'assurer de la stabilité du nœud maître.
- Il est conseillé pour de gros cluster de ne pas charger les nœuds maîtres avec des travaux d'ingestion, d'indexation ou de recherche.

```
node.master: true
node.data: false
node.ingest: false
```

search.remote.connect: false

Configurations des nœuds

Configuration d'un nœud de données

node.master: false
node.data: true
node.ingest: false

search.remote.connect: false

Configuration d'un nœud d'ingestion

node.master: false
node.data: false
node.ingest: true

search.remote.connect: false

Configuration d'un nœud de coordination

node.master: false
node.data: false
node.ingest: false

search.remote.connect: false

Bootstraping ELS

- Lors du premier démarrage du cluster en production, il est nécessaire de spécifier cluster.initial_master_nodes qui liste la liste des nœuds maîtres éligibles. (En général, les noms des nœuds sont précisés)
- Ensuite, lors d'un redémarrage de nœud, la recherche du maître s'effectue avec :
 - Les hôtes listés dans discovery.seed_hosts
 - Le dernier maître connu

Mémoire heap

- L'installation par défaut d'ELS est configuré avec 1 GB de heap (mémoire JVM). Ce nombre est bien trop petit
- 3 façons pour changer la taille de la heap.
 - Le fichier jvm.options
 - Via la variable d'environnement ES_HEAP_SIZE export ES HEAP SIZE=10g
 - Via la commande en ligne
 ./bin/elasticsearch -Xmx=10g -Xms=10g
- 2 recommandations standard:
 - donner 50% de la mémoire disponible à ELS et laisser l'autre moitié vide. En fait Lucene occupera allègrement l'autre moitié
 - Ne pas dépasser 32Go

Swapping

- Éviter le swapping à tout prix.
- Éventuellement, le désactiver au niveau système

sudo swapoff -a

Ou au niveau ELS

boostrap.memory lock: true

(Anciennement bootstrap.mlockall)

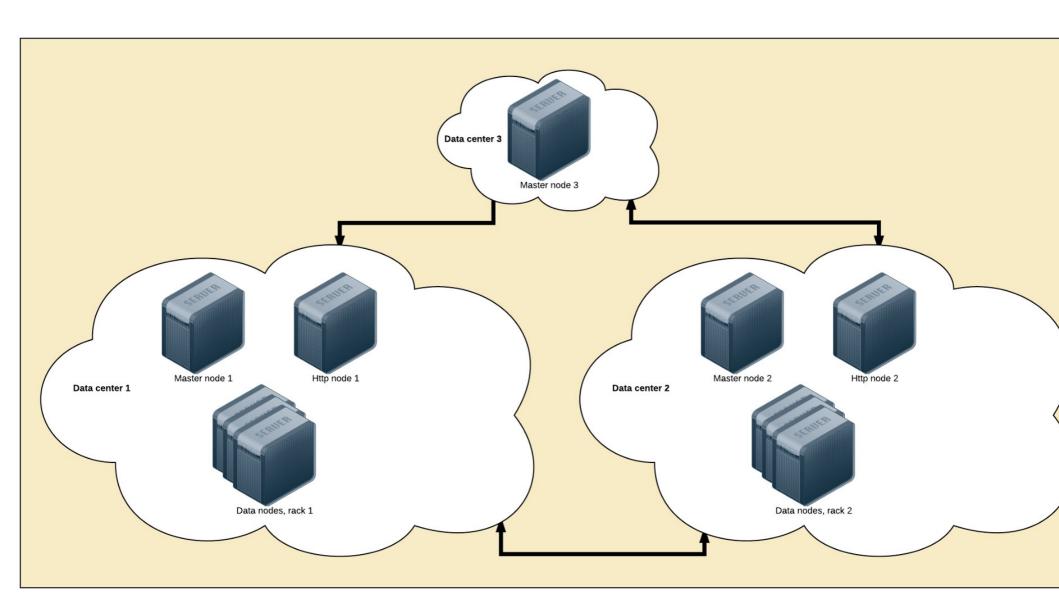
Descripteurs de fichiers

- Lucene utilise énormément de fichiers. ELS énormément de sockets
- La plupart des distributions Linux limite le nombre de descripteurs e fichiers à 1024.
- Cette valeur doit être augmenté à 64,000

Architecture fault-tolerant

- Une architecture tolérante aux pannes typique est de distribuer les nœuds sur différents data center
 - au minimum 2 data center principaux contenant les nœuds de données et 1 de backup contenant un éventuel master node
 - 3 master node
 - 2 nœuds pour exécuter les requêtes http (1 par data center principal)
 - Des nœuds de données distribués sur les 2 data center principaux

Architecture fault-tolerant



Déploiement en production

Architectures ingestion
Monitoring Logstash
Architecture Indexation/Recherche

Cycle de vie des index, Gestion des shards
Monitoring ES
Exploitation

Segments Lucene

- Chaque shard d'Elasticsearch est un index Lucene.
- Un index Lucene est divisé en de petits fichiers : les segments

Elasticsearch Index							
Elasticsearch shard		Elasticsearch shard		Elasticsearch shard		Elasticsearch shard	
Lucene index		Lucene index		Lucene index		Lucene index	
Segment	Segment	Segment	Segment	Segment	Segment	Segment	Segment

Fusion de segments

- Lucene crée des segments lors de l'indexation. Les segments sont immuables
- Lors d'une recherche, les segments sont traités de façon séquentielle
 => Plus il y a de segments, plus les performances de recherche diminuent
- Pour optimiser la recherche, Lucene propose l'opération merge qui fusionne de petits segments en de plus gros.
 - C'est une opération assez lourde qui peut impacter les opérations d'indexation et de recherche. Elle est effectué périodiquement par un pool de threads dédié
 - On peut forcer une opération de merge :
 curl -XPOST 'localhost:9200/logstash-2017.07*/_forcemerge?
 max num segments=1'
 - Pour que le merge réussisse, il faut que l'espace disque soit 2 fois la taille du shard

Dimensionnement du nombre de shards

- Le nombre de shards est défini lors de la création de l'index. (Par défaut : 5)
- Seulement la charge réelle permet de trouver la bonne valeur pour le nombre de shards.
- Redimensionner un index en production nécessite une réindexation et éventuellement l'utilisation d'alias d'index.

Avantages pour de nombreux shards

- Disposer de beaucoup de shards sur de gros indices et de gros cluster (Plus de 20 nœuds de données) apporte certains avantages :
 - Meilleures allocations entre les nœuds
 - De petits shards sur beaucoup de nœuds rend le processus de recovery plus rapide (Perte d'un nœud de données ou arrêt du serveur).
 - Cela peut régler des problèmes mémoire, lorsque l'on exécute de grosses requêtes.
 - Les gros shards rendent les processus d'optimisation de Lucene plus difficile. Lors d'une fusion de segments Lucene, il faut avoir 2 fois la taille du shard comme espace libre.
- Par contre, avoir de nombreux shards peut surcharger le master et le cluster devient alors très instable

Recommandations

• Repère :

 Des shards de 10GB semblent offrir un bon compromis entre la vitesse d'allocation, et la gestion du cluster.

=> Pour une moyenne de 2GB pour 1 million de documents :

- De 0 à 4 millions de documents par index: 1 shard.
- De 4 à 5 million documents par index: 2 shards
- > 5 millions documents : 1 shards par 5 millions.

Exemple de script de resizing

```
#!/bin/bash
for index in $(list of indexes); do
 documents=$(curl -XGET http://cluster:9200/${index}/ count 2>/dev/null | cut -f 2 -d : | cut -f 1 -d ',')
 # Dimensionnement du nombre de shard enn fonction du nbre de documents
 if [ $counter - lt 4000000 ]; then
    shards=1
  elif [ $counter -lt 5000000 ]; then
      shards=2
  else
      shards=\$(( \$counter / 5000000 + 1))
 fi
  new version=\$((\$(echo \$\{index\} \mid cut -f 1 -d ) + 1))
  index name=$(echo ${index} | cut -f 2 -d )
  curl -XPUT http://cluster:9200/${new version}${index name} -d '{
  "number of shards" : '${shards}'
curl -XPOST http://cluster:9200/ reindex -d '{
  "source": {
    "index": "'${index}'"
  },
  "dest": {
    "index": "'${new version}${index name}'"
}'
              https://thoughts.t37.net/resizing-your-elasticsearch-indexes-in-production-d7a0402d137e
done
```

Gestion du lifecycle des index

- Il est possible d'automatiser des actions de gestion du cycle de vie des index comme :
 - Rollover : Redirigez un alias pour commencer à écrire dans un nouvel index lorsque l'index existant atteint un certain âge, nombre de documents ou taille.
 - Shrink : Réduire le nombre de shards primaires dans un index.
 - Force merge : Réduire le nombre de segments dans chaque shards d'un index et libérer l'espace utilisé par les documents supprimés.
 - Freeze : Rendre un index read-only et minimiser son empreinte mémoire
 - **Delete** : Supprimer un index

Mécanisme

- En pratique, il faut associer une stratégie de cycle de vie avec un gabarit d'index, afin qu'il soit appliqué aux index nouvellement créés.
- La stratégie de cycle de vie définit les conditions pour faire un index dans ses différentes de son cycle de vie :
 - Hot : L'index est mis à jour et interrogé
 - *Warm* : L'index n'est plus mis à jour mais encore interrogé.
 - Cold: L'index n'est plus mis à jour et est rarement interrogé.
 Les informations sont toujours consultables, mais les requêtes sont plus lentes
 - Delete: L'index n'est plus utilisé et peut être supprimé.

Stratégies

- Une stratégie de cycle de vie consiste à spécifier :
 - Taille ou âge maximum pour effectuer le rollover.
 - Le moment où l'index n'est plus mis à jour et ou le nombre de shards primaires peut être réduit.
 - Le moment pour forcer la fusion
 - Le moment ou on peut déplacer l'index vers un matériel moins performant.
 - Le moment où la disponibilité n'est pas aussi critique et le nombre de répliques peut être réduit.
 - Le moment où l'index peut être supprimé en toute sécurité.

Création

```
• PUT _ilm/policy/datastream_policy
   "policy": {
     "phases": {
       "hot": {
         "actions": {
           "rollover": {
             "max_size": "50GB",
             "max_age": "30d"
       "delete": {
         "min_age": "90d",
         "actions": {
           "delete": {}
```

Création de gabarit puis du premier index

```
• PUT _template/datastream_template
    "index_patterns": ["datastream-*"],
    "settings": {
      "number of shards": 1,
      "number_of_replicas": 1,
      "index.lifecycle.name": "datastream_policy",
      "index.lifecycle.rollover_alias": "datastream"
• PUT datastream-000001
   "aliases": {
      "datastream": {
        "is write index": true
• GET datastream-*/_ilm/explain
```

Déploiement en production

Architectures ingestion
Monitoring Logstash
Architecture Indexation/Recherche
Cycle de vie des index, Gestion des shards

Monitoring ES

Exploitation

X-Pack

- ELS offre une API permettant d'obtenir certains métriques d'un cluster
- La version X-Pack permet de disposer de tableaux de bord Kibana pour la surveillance en continue du cluster

Cluster Health API

```
GET cluster/health
"cluster name": "elasticsearch zach",
"status": "green", // green, yellow or red
"timed out": false,
"number of nodes": 1,
"number of data nodes": 1,
"active primary shards": 10,
"active shards": 10,
"relocating shards": 0,
"initializing shards": 0,
"unassigned shards": 0
}
```

Information au niveau des index

```
GET cluster/health?level=indices
"cluster_name": "elasticsearch_zach",
"status": "red",
"unassigned_shards": 20
"indices": {
  "v1": {
    "status": "green",
    "number of shards": 10,
    "number of replicas": 1,
     "active_primary_shards": 10,
     "active shards": 20,
     "relocating_shards": 0,
     "initializing_shards": 0,
     "unassigned_shards": 0
},
```

node-stats API

```
GET nodes/stats
"cluster name": "elasticsearch zach",
"nodes": {
"UNr6ZMf5Qk-YCPA L18B0Q": {
"timestamp": 1408474151742,
"name": "Zach",
"transport address":
"inet[zacharys-air/192.168.1.131:9300]",
"host": "zacharys-air",
"ip": [
"inet[zacharys-air/192.168.1.131:9300]",
"NONE"
```

Sections indices

- La section *indices* liste des statistiques agrégés pour tous les les index d'un nœud.
- Il contient les sous-sections suivantes :
 - docs : combien de documents résident sur le nœud, le nombre de documents supprimés qui n'ont pas encore été purgés
 - **store** indique l'espace de stockage utilisé par le nœud
 - indexing le nombre de documents indexés
 - get : Statistiques des requêtes get-by-ID
 - search : le nombre de recherches actives, nombre total de requêtes le temps d'exécution cumulé des requêtes
 - *merges* fusion de segments de Lucene
 - *filter_cache* : la mémoire occupée par le cache des filtres
 - id_cache répartition de l'usage mémoire
 - field_data mémoire utilisée pour les données temporaires de calcul (utilisé lors d'agrégation, le tri, ...)
 - **segments** le nombre de segments Lucene. (chiffre normal 50–150)

Section OS et processus

- Ce sont les chiffres basiques sur la charge CPU et l'usage mémoire au niveau système
 - CPU
 - Usage mémoire
 - Usage du swap
 - Descripteurs de fichiers ouverts

Section JVM

- La section jvm contient des informations critiques sur le processus JAVA
- En particulier, il contient des détails sur la collecte mémoire (garbage collection) qui a un gros impact sur la stabilité du cluster
- La chose à surveiller est le nombre de collectes majeures qui doit rester petit ainsi que le temps cumulé dans les collectes collection_time_in_millis.
- Si les chiffres ne sont pas bon, il faut rajouter de la mémoire ou des nœuds.

Section pool de threads

- ELS maintient des pools de threads pour ses tâches internes.
- En général, il n'est pas nécessaire de configurer ces pools.

File system et réseau

- ELS fournit des informations sur votre **système de fichiers** : Espace libre, les répertoires de données, les statistiques sur les IO disques
- Il y a également 2 sections sur le **réseau**
 - transport: statistiques basiques sur les communications inter-nœud (port TCP 9300) ou clientes
 - http: Statistiques sur le port HTTP. Si l'on observe un très grand nombre de connexions ouvertes en constante augmentation, cela signifie qu'un des clients HTTP n'utilise pas les connexions keep-alive. Ce qui est très important pour les performances d'ELS

Index stats API

 L'index stats API permet de visualiser des statistiques vis à vis d'un index

```
GET my_index/_stats
```

 Le résultat est similaire à la sortie de nodestats : Compte de recherche, de get, segments, ...

Déploiement en production

Architectures ingestion
Monitoring Logstash
Architecture Indexation/Recherche
Monitoring ES
Exploitation

Changement de configuration

- La plupart des configurations ELS sont dynamiques, elles peuvent être modifiées par l'API.
- L'API cluster-update opère selon 2 modes :
 - transient : Les changements sont annulés au redémarrage
 - persistent : Les changements sont permanents. Au redémarrage, ils écrasent les valeurs des fichiers de configuration

Exemple

```
PUT /_cluster/settings
{
   "persistent" : {
   "discovery.zen.minimum_master_nodes" : 2
},
   "transient" : {
   "indices.store.throttle.max_bytes_per_sec" : "50mb"
647}
}
```

Fichiers de trace

- ELS écrit de nombreuses traces dans ES_HOME/logs. Le niveau de trace par défaut est INFO
- On peut le changer par l'API

```
PUT /_cluster/settings
{
    "transient" : { "logger.discovery" : "DEBUG" }
}
```

Slowlog

- L'objectif du slowlog est de logger les requêtes et les demandes d'indexation qui dépassent un certain seuil de temps
- Par défaut ce fichier journal n'est pas activé. Il peut être activé en précisant l'action (query, fetch, ou index), le niveau de trace (WARN, DEBUG, ..) et le seuil de temps
- C'est une configuration au niveau index

```
PUT /my_index/_settings
{ "index.search.slowlog.threshold.query.warn" : "10s",
  "index.search.slowlog.threshold.fetch.debug": "500ms",
  "index.indexing.slowlog.threshold.index.info": "5s" }

PUT /_cluster/settings
{ "transient" : {
    "logger.index.search.slowlog" : "DEBUG",
    "logger.index.indexing.slowlog" : "WARN"
} }
```

Backup

- Pour sauvegarder un cluster, l'API snapshot API peut être utilisé
- Cela prend l'état courant du cluster et ses données et le stocke dans une dépôt partagé
- Le premier snapshot est intégral, les autres sauvegardent les deltas
- Les dépôts peuvent être de diffférents types
 - Répertoire partagé (NAS par exemple)
 - Amazon S3
 - HDFS (Hadoop Distributed File System)
 - Azure Cloud

Usage simple

```
PUT snapshot/my backup
"type": "fs",
"settings": {
  "location": "/mount/backups/my backup"
} }
Ensuite
PUT _snapshot/my backup/snapshot 1
```

Restauration

POST _snapshot/my_backup/snapshot_1/_restore

- Le comportement par défaut consiste à restaurer tous les index existant dans le snapshot
- Il est également possible de spécifier les index que l'on veut restaurer

MERCI!!

Pour votre attention

Annexes

FileBeat
Pipelines ElasticSearch
Analyseurs
Contrôle du score
Surbrillance
Librairies clientes
Machine Learning

Annexes

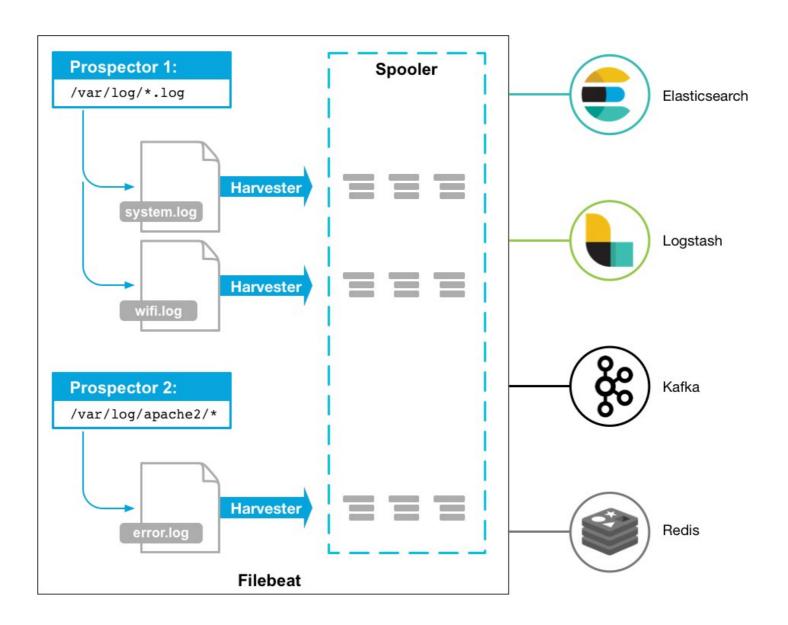
FileBeat

Pipelines ElasticSearch
Analyseurs
Contrôle du score
Surbrillance
Librairies clientes
Machine Learning

Prospecteur et Harvester

- 2 concepts dans Filebeat
 - Harvester: Composant responsable de lire un fichier. Il garantit que chaque ligne d'un fichier sera envoyé une et une seule fois
 - Prospector : Composant responsable de créer les harvester nécessaires

Filebeat



Configuration

- La configuration de Filebeat consiste à :
 - Spécifier les modules à exécuter.
 - 1 module correspond à un format classique de trace
 - Spécifier les prospecteurs
 - principalement les chemins vers les fichiers de trace à consommer
 - Gérer les messages multi-lignes
 - en indiquant des expressions régulières permettant de fusionner plusieurs lignes dans un même événement
 - Les options générales de filebeat
 - · emplacement du fichier de config
 - et les options communes à tous les beats
 - nom du convoyeur, tags
 - Configurer la file d'attente de traitement des événements

Configuration (2)

- La configuration de *Filebeat* consiste à :
 - Configurer la sortie
 - cluster logstash ou elasticsearch, répartition de la charge, éventuellement SSL
 - Filtrer ou enrichir les données des fichiers
 - Exclure ou ajouter des lignes (moins de possibilités qu'avec logstash)
 - Utiliser une pipeline de traitement côté ELS
 - moins de possibilité qu'avec logstash
 - Spécifier le hôte Kibana pour l'importation des tableaux de bord (6.x)
 - Charger les tableaux de bords Kibana
 - soit manuellement, soit automatiquement au 1^{er} démarrage
 - Charger les gabarits d'index ELS
 - soit manuellement, soit automatiquement au 1^{er} démarrage
 - Configurer le niveau de trace

Activation des modules

- Les modules sont activés de différentes façons :
 - Par les commandes en ligne modules enable ou modules disable.

C'est la méthode recommandée. Ex :

- ./filebeat modules enable apache2 mysql
- La commande joue sur le répertoire *modules.d* qui contient toutes les configurations par défaut
- Lors de l'exécution de filebeat
 ./filebeat -e --modules nginx, mysql, system
- Via le fichier de configuration filebeat.yml

filebeat.modules:

- module: nginx- module: mysql- module: system

Modules disponibles

- Apache2, Nginx
- System (auth, syslog), Auditd (démon auditd)
- Kafka, Redis,
- Logstash
- Mysql, Postgres
- Traefik

Exemple System Module

- Le module permet :
 - Positionner les chemins par défaut des fichiers de logs
 - Garantir que les traces multi-lignes seront traitées comme un événement unique
 - D'utiliser les nœuds d'ingestion d'ELS
 - Déployer les tableaux de bord

Exemple module *System*Mise en place

- Activer le module dans la configuration
- ./filebeat modules enable system
- Initialisation, importation des gabarits et des tableaux de bord
- ./filebeat setup -e
- Démarrage
- ./filebeat -e

Annexes

FileBeat

Pipelines ElasticSearch

Analyseurs

Contrôle du score

Surbrillance

Librairies clientes

Machine Learning

Introduction

- Sans logstash, il est possible d'effectuer des transformations courantes sur les données avant l'indexation en utilisant les pipelines d'ingestion d'ElasticSearch
- Les fonctionnalités sont similaires à logstash mais moins puissantes
- Les pipelines ELS peuvent être utilisés pour supprimer des champs, extraire des valeurs du texte et enrichir vos données.
- Il se compose d'une série de tâches configurables appelées processeurs. Chaque processeur s'exécute de manière séquentielle, apportant des modifications spécifiques aux documents entrants

Pipeline

- Une **pipeline** est définie par :
 - Un nom
 - Une description
 - Et une liste de *processors* (*pré-définis*)
- Les processors sont executés en séquence

Ingest API

- L'API _ingest supporte :
 - **PUT**: Ajout ou remplacement d'une pipeline
 - **GET** : Récupération d'une pipeline
 - **DELETE**: Suppression d'une pipeline
 - SIMULATE : Simulation de l'exécution d'une pipeline

Usage

```
#Creation d'une pipeline nommée attachment
PUT ingest/pipeline/attachment
  "description" : "Extract attachment information",
  "processors" : [
    { "attachment" : { "field" : "data" } }
# Utilisation d'une pipeline durant l'indexation.
PUT my_index/my_type/my_id?pipeline=attachment
  "data":
"e1xydGYxXGFuc2kNCkxvcmVtIGlwc3VtIGRvbG9yIHNpdCBhbWV0DQp
ccGFyIH0="
```

Résultat

```
GET my index/my type/my id
{
  "found": true,
  "_index": "my_index",
  "_type": "my_type",
  "_id": "my_id",
  "_version": 1,
  " source": {
    "data":
"e1xydGYxXGFuc2kNCkxvcmVtIGlwc3VtIGRvbG9yIHNpdCBhbWV0DQpccGFyIH0=",
    "attachment": {
      "content_type": "application/rtf",
      "language": "ro",
      "content": "Lorem ipsum dolor sit amet",
      "content length": 28
```

Introduction aux plugins

- Les fonctionnalités d'ELS peuvent être étendues via la notion de plugin
- Les Plugins contiennent des fichiers JAR, mais aussi des scripts et des fichiers de configuration
- Ils peuvent être installés facilement avec
 - sudo bin/elasticsearch-plugin install [plugin_name]
 - Ils doivent être installés sur chaque nœud du cluster
 - Après une installation, le nœud doit être redémarré

Ingest plugins

- Un plugin d'ingestion particulier permet d'indexer des documents bureautiques (Word, PDF, XLS, ...) :
 - Attachment Plugin: Extrait les données textuelles des pièces jointes dans différents formats (PPT, XLS, PDF, etc.). Utilise la librairie Apache Tika.

•

 sudo bin/elasticsearch-plugin install ingestattachment

Annexes

FileBeat
Pipelines ElasticSearch
Analyseurs
Contrôle du score
Surbrillance
Librairies clientes
Machine Learning

Tokenisation et Normalisation

- Pour construire l'index inversé, ELS doit séparer un texte en mots (tokenisation) et ensuite normaliser les mots afin que la recherche du terme « envoi » par exemple retourne des documents contenant : « envoi », « Envoi », « envois », « envoyer », …
- La tokenisation et la normalisation sont appelées analyse.
- L'analyse s'applique sur les documents lors de l'indexation ET lors de la recherche sur les termes recherchés.

Étapes de l'analyse

- Les analyseurs transforment un texte en un flux de "token". Ils peuvent être constitués d'une seule classe Java ou d'une combinaison de filtres, de tokenizer et de filtres de caractères
 - Les filtres de caractères préparent le texte en effectuant du remplacement de caractères (& devient et) ou en supprimant (suppression des balises HTML)
 - Les **tokenizers** splittent un texte en une suite d'unité lexicale : les tokens
 - Les *filtres* prend en entrée un flux de token et le transforme en un autre flux de token

Analyseurs prédéfinis

- ELS propose des analyseurs directement utilisables :
 - Analyseur Standard : C'est l'analyseur par défaut. Le meilleur choix lorsque le texte est dans des langues diverses. Il consiste à :
 - Séparer le texte en mots
 - Supprime la ponctuation
 - Passe tous les mots en minuscule
 - **Analyseur simple** : Sépare le texte en token de 2 lettres minimum puis passe en minuscule
 - Analyseur d'espace : Sépare le texte en fonction des espaces
 - Analyseurs de langues : Ce sont des analyseurs spécifiques à la langue. Ils incluent les « stop words » (enlève les mots les plus courant) et extrait la racine d'un mot. C'est le meilleur choix si l'index est en une seule langue

Test des analyseurs

```
GET /_analyze?analyzer=standard
Text to analyze
<u>Réponse</u>:
"tokens": [ {
  "token": "text",
  "start offset": 0,
  "end offset":4,
  "type": "<ALPHANUM>",
  "position": 1
}, {
  "token": "to",
  "start offset": 5,
  "end_offset": 7,
  "type": "<ALPHANUM>",
  "position": 2
}, {
  "token": "analyze",
  "start offset": 8,
  "end offset": 15,
  "type":"<ALPHANUM>",
  "position": 3
} ] }
```

Spécification des analyseurs

- Lorsque ELS détecte un nouveau champ String dans un type de document, il le configure automatiquement comme champ fulltext et applique l'analyseur standard.
- Si ce n'est pas le comportement voulu, il faut explicitement spécifier le mapping pour le type de document

Analyseurs

- L'analyseur par défaut est l'analyseur standard qui consiste en :
 - Le tokenizer standard qui sépare sur les frontières de mots
 - Le <u>filtre de token standard</u> (qui ne fait rien)
 - Le filtre <u>lowercase</u> qui passe tout en minuscule
 - Le filtre <u>stopwords</u> (qui contient un minimum de stop words)
- Il est possible de surcharger cette configuration par défaut en ajoutant un filtre ou en remplaçant un existant

Création par surcharge

 Dans l'exemple suivant, un nouvel analyseur fr_std pour l'index french_docs est créé. Il utilise la liste prédéfinie des stopwords français :

Création complète

• Il est possible de créer ses propres analyseurs en combinant des filtres de caractères, un tokenizer et des filtres de tokens :

```
- 0 ou n : Filtres de caractères
- 1 : tokenizer
- 0 ou n : Filtre de tokens

PUT /my_index
{
   "settings": {
       "analysis": {
       "char_filter": { ... custom character filters ... },
       "tokenizer": { ... custom tokenizers ... },
       "filter": { ... custom token filters ... },
       "analyzer": { ... custom analyzers ... }
} } }
```

Exemple

```
PUT /my_index
"settings": {
  "analysis": {
   "char_filter": {
     "&_to_and": {
       "type": "mapping",
        "mappings": [ "&=> and "]
       }}, "filter": {
        "my_stopwords": {
          "type": "stop",
          "stopwords": [ "the", "a" ]
        }},
        "analyzer": {
          "my_analyzer": {
            "type": "custom",
             "char_filter": [ "html_strip", "&_to_and" ],
             "tokenizer": "standard",
             "filter": [ "lowercase", "my_stopwords" ]
}}
}}}
```

Affectation à un index

• Il faut ensuite associer l'analyseur à un champ string

```
PUT /my index/ mapping
"properties": {
"title": {
  "type":"text",
  "analyzer": "my_analyzer"
```

Analyseurs prédéfinis

- Elasticsearch fournit des analyseurs pré-définis pouvant être utilisés directement :
 - Standard (par défaut) : Sépare en mot, enlève la ponctuation, passe en minuscule, supporte les stop words
 - Simple : Sépare en token dés qu'il trouve un caractère qui n'est pas une lettre. Passe en minuscule
 - Whitespace: Se base sur les espaces pour la tokenization. Ne passe pas en minuscule
 - Stop: Comme l'analyseur simple avec du support pour les stop words.
 - **Keyword** : Ne fait rien. Prend le texte tel quel
 - Pattern: Utilise une expression régulière pour la tokenization. Passe en minuscule et supporte les stop words.
 - Language : english, french, ...
 - Fingerprint : Crée une empreinte du document pouvant être utilisé pour tester la duplication.

Filtres fournis

- ELS fournit de nombreux filtres permettant de mettre au point des analyseurs personnalisés. Citons :
 - Length Token: Suppression de mots trop courts ou trop longs
 - N-Gram et Edge N-Gram : Analyzeur permettant d'accélérer les suggestion de recherche
 - Stemming filters : Algorithme permettant d'extraire la racine d'un mot
 - Phonetic filters : Représentation phonétique des mots
 - **Synonym**: Correspondance de mots
 - Keep Word : Le contraire de stop words
 - Limit Token Count : Limite le nombre de tokens associés à un document
 - Elison Token : Gestion des apostrophes (français)

Utilisation de synonymes

- Les synonymes peuvent être utilisés pour fusionner des mots qui ont quasiment le même sens.
 - Ex : joli, mignon, beau
- Ils peuvent également être utilisés afin de rendre un mot plus générique.
 - Par exemple, oiseau peut être utilisé comme synonyme à pigeon, moineau, ...

Ajout d'un filtre synonyme

3 utilisations

- Le remplacement de synonyme peut se faire de 3 façons :
 - Expansion simple : Si un des termes est rencontré, il est remplacé par tous les synonymes listés "jump,leap,hop"
 - Contraction simple : un des termes rencontré est remplacé par un synonyme "leap,hop => jump"
 - Expansion générique : un terme est remplacé par plusieurs synonymes "puppy => puppy,dog,pet"

Annexes

FileBeat
Pipelines ElasticSearch
Analyseurs
Contrôle du score
Surbrillance
Librairies clientes
Machine Learning

Tri

- Lors de requêtes de type filtre, il peut être intéressant de définir le critère de tri.
- Cela se fait via le paramètre sort

```
GET /_search
{
    "query" : {
        "bool" : {
            "filter" : { "term" : { "user_id" : 1 }}
      }
    }, "sort": { "date": { "order": "desc" }}
}
```

Réponse

• Dans la réponse, le champ _score n'est pas calculé et la valeur du champ de tri est précisée pour chaque document

```
"hits" : {
    "total" : 6,
    "max_score" : null,
    "hits" : [ {
        "_index" : "us",
        "_type" : "_doc",
        "_id" : "14",
        "_score" : null,
        "_source" : {
        "date": "2014-09-24",
        ...
    }, "sort" : [ 14115168000000 ]
},
...
}
```

Plusieurs critères de tri

• Il est possible de combiner un critère de tri avec un autre critère ou le score. Attention l'ordre est importante.

Tri sur les champs multi-valués

• Il est également possible d'utiliser une fonction d'agrégation pour trier les champs multivalués (min, max, sum, avg, ...)

```
"sort": {
    "dates": {
        "order": "asc",
        "mode": "min"
    }
}
```

Pertinence

- Le score de chaque document est représenté par un nombre à virgule (_score). Plus ce chiffre est élevé, plus le document est pertinent.
- L'algorithme utilisé par ELS est dénommé term frequency/
- *inverse document frequency*, ou *TF/IDF*. Il prend en compte les facteurs suivants :
 - La **fréquence du terme** : combien de fois apparaît le terme dans le champ
 - La **fréquence inverse au niveau document** : Combien de fois apparaît le terme dans l'index ? Plus le terme apparaît moins il a de poids.
 - La longueur du champ normalisée : Plus le champ est long, moins les mots du document sont pertinents
- En fonction du type de requête (requête floue, ...) d'autres facteurs peuvent influencer le score

Explication de la pertinence

• Avec le paramètre explain, ELS fournit une explication du score

```
GET / search?explain
{ "query"
: { "match" : { "tweet" : "honeymoon" }}
}
• Le paramètre explain qui peut être utilisé pour comprendre si un document
  matches ou pas.
GET /us/12/ explain
{
"query" : {
  "bool" : {
    "filter" : { "term" : { "user id" : 2 }},
    "must" : { "match" : { "tweet" : "honeymoon" }}
} } }
```

Réponse

```
" explanation": {
  "description": "weight(tweet:honeymoon in 0)
  [PerFieldSimilarity], result of:",
  "value": 0.076713204,
  "details": [ {
    "description": "fieldWeight in 0, product of:",
    "value": 0.076713204,
    "details": [ {
      "description": "tf(freq=1.0), with freq of:",
      "value": 1,
      "details": [ {
        "description": "termFreq=1.0",
        "value": 1
      } ]
    }, {
      "description": "idf(docFreq=1, maxDocs=1)",
      "value": 0.30685282
    }, {
       "description": "fieldNorm(doc=0)",
       "value": 0.25,
    } ]
} ] }
```

multi_match

- La requête multi_match facilite l'exécution de la même requête sur plusieurs champs.
- Le joker peut être utilisé ainsi que des facteurs de boost

```
• "multi_match": {
• "query": "Quick brown fox",
• "type": "best_fields",
• "fields": [ "*_title^2", "body" ],
• "tie_breaker": 0.3,
• "minimum_should_match": "30%"
• } }
```

Cas de *multi_match*

- Le paramètre *type* précise le fonctionnement de l'opérateur et le calcul du score.
 - best_fields (défaut) : Trouve les documents qui match avec un des champs mais utilise le meilleur champ pour affecter le score
 - *most_fields* : Combine le score de chaque champ
 - cross_fields : Concatène tous les champs et utilise le même analyseur
 - phrase : Utilise un match_phrase sur chaque champ et combine le score de chaque champ
 - phrase_prefix : Utilise un match_phrase_prefix sur chaque champ et combine le score de chaque champ

Cas de bool

 Le calcul de la pertinence s'effectue en additionnant le score de chaque clause must ou should et en divisant par 4

Boosting clause

 Il est possible de donner plus de poids à une clause particulière en utilisant le paramètre boost

```
GET /_search
{
"query": { "bool": {
    "must": { "match": {
        "content": { "query": "full text search", "operator": "and" }}},
        "should": { "match": {
            "content": { "query": "Elasticsearch", "boost": 3 }}}
} }}
```

Opérateur boosting

 L'opérateur boosting permet d'indiquer une clause qui réduit le score des documents qui matchent

```
GET /_search
{
    "query": {
        "boosting" : {
            "term" : {"text" : "apple"}
        },
        "negative" : {
            "term" : { "text" : "pie tart fruit crumble tree" }
        },
        "negative_boost" : 0.5 // requis le malus au document qui matche
     }
}
```

dis_max

- Au lieu de combiner les requêtes via bool, il peut être plus pertinent d'utiliser dis_max
- dis_max est un OR mais le calcul de la pertinence diffère
- *Disjunction Max Query* signifie : retourne les documents qui matchent une des requêtes et retourne le score de la requête qui matche le mieux

tie_breaker

• Il est également possible de tenir compte des autres requêtes qui match en leur donnant une plus petite importance.

C'est le paramètre *tie_breaker*

- Le calcul du score est alors effectué comme suit :
 - 1. Prendre le score de la meilleure clause .
 - 2. Multiplier le score de chaque autres clauses qui matchent par le tie_breaker.
 - 3. Les ajouter et les normaliser

Function score query

- Le bloc fonction_score permet de modifier le score des documents récupérés par une requête.
- Différentes fonctions pour évaluer le score peuvent être utilisées :
 - script_score : personnaliser avec un calcul dérivé d'autres valeurs de champs numériques dans le document à l'aide d'une expression de script
 - weight : permet de multiplier le score par le poids fourni
 - random_score génère des scores uniformément distribués
 - field_value_factor : La fonction vous permet d'utiliser un champ d'un document pour influencer le score. C'est similaire à l'utilisation du script_score

Exemple: script_score

```
GET /_search
{
  "query": {
    "function_score": {
      "query": {
        "match": { "message": "elasticsearch" }
      "script_score": {
        "script": {
          "source": "Math.log(2 + doc['views'].value)"
```

Example Field Value factor

```
GET /_search
  "query": {
    "function_score": {
      "field_value_factor": {
        "field": "my-int",
        "factor": 1.2,
        "modifier": "sqrt",
        "missing": 1
```

Annexes

FileBeat
Pipelines ElasticSearch
Analyseurs
Contrôle du score
Surbrillance
Librairies clientes
Machine Learning

Introduction

- La surbrillance consiste à mettre en valeur le terme ayant matché dans le contenu original qui a été indexé.
- Cela est possible grâce aux métadonnées stockées lors de l'indexation
- Le champ original doit être stocké par ELS

Exemple

```
GET /_search
  "query" : {
    "bool" : {
      "must" : { "match" :
{ "attachment.content" : "Administration"} },
      "should" : { "match" : { "attachment.content" :
"Oracle" } }
  },
  "highlight" : {
        "fields" : {
            "attachment.content" : {}
```

Réponse

```
"highlight" : {
          "attachment.content" : [
            " formation <em>Administration</em> <em>Oracle</em>
Forms/Report permet de voir tous les aspects nécessaires à",
            " aux autres services Web de l'offre
<em>Oracle Fusion Middleware. Cependant, l'administration
de ces".
            " Surveillance. Elle peut-être un complément de la
formation « <em>Administration</em> d'un serveveur Weblogic",
            "-forme <em>Oracle</em> Forms ou des personnes
désirant migrer leur application client serveur Forms vers",
            " <em>Oracle</em> Forms 11g/12c\nPré-requis : \
nExpérience de l'administration système\nLa formation
« Administation"
```

Spécifier les balises

```
GET /_search
  "query" : {
    "bool" : {
      "must" : { "match" :
{ "attachment.content" : "Administration"} },
      "should" : { "match" : { "attachment.content" : "Oracle" } }
  },
  "highlight" : {
        "pre tags" : ["<tag1>"],
        "post_tags" : ["</tag1>"],
        "fields" : {
            "attachment.content" : { "type" : "plain"}
```

Fragments mis en valeur

- Il est possible de contrôler les fragments mis en valeur pour chaque champ :
 - fragment_size : donne la taille max du fragment mis en surbrillance
 - number_of fragments : Le nombre maximal de fragments dans ce champ

Annexes

FileBeat
Pipelines ElasticSearch
Analyseurs
Contrôle du score
Surbrillance
Librairies clientes
Machine Learning

Introduction

- ElasticSearch distributes a set of integration libraries for different languages or frameworks:
 - Java + framework SpringBoot + ...
 - JavaScript
 - Ruby
 - Go
 - .NET
 - PHP
 - Perl
 - Python
- Other libraries provided by third-parties are also available

Features

- The use of a library (comparer to low level REST calls) brings some benefits:
 - Strongly typed requests and responses for all Elasticsearch APIs.
 - Blocking and asynchronous versions of all APIs.
 - Use of fluent builders and functional patterns to allow writing concise yet readable code when creating complex nested structures.
 - Seamless integration of application classes by using an object mapper such as Jackson or any JSON-B implementation.
 - Delegates protocol handling to an http client such as the Java Low Level REST Client that takes care of all transport-level concerns: HTTP connection pooling, retries, node discovery, and so on.

Example Java : Connection

```
• // Create the low-level client

    RestClient restClient = RestClient.builder(

     new HttpHost("localhost", 9200)).build();
• // Create the transport with a Jackson mapper
• ElasticsearchTransport transport = new
 RestClientTransport(
     restClient, new JacksonJsonpMapper());
• // And create the API client
• ElasticsearchClient client = new
 ElasticsearchClient(transport);
```

Request

```
SearchResponse<Product> search = client.search(s
-> S
    .index("products")
    .query(q -> q
        .term(t \rightarrow t)
             .field("name")
             .value(v -> v.stringValue("bicycle"))
        )), Product.class);
for (Hit<Product> hit: search.hits().hits()) {
    processProduct(hit.source());
```

Annexes

FileBeat
Pipelines ElasticSearch
Analyseurs
Machine Learning

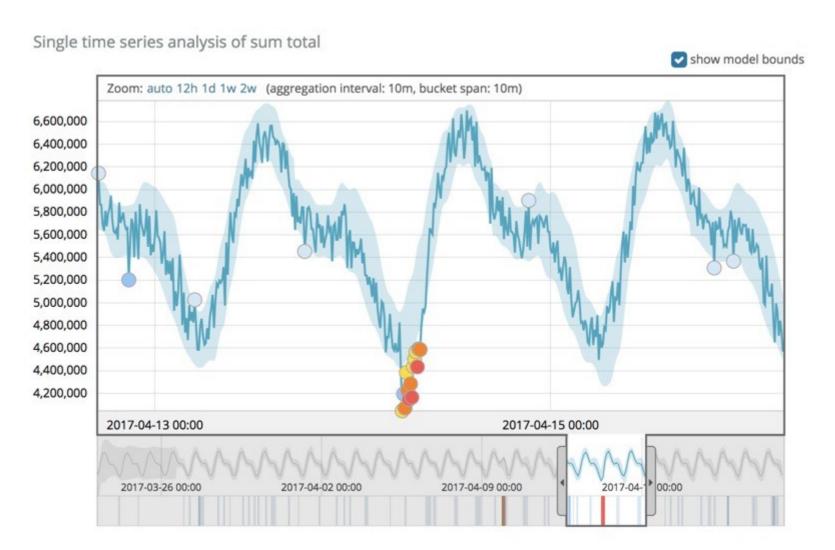
Introduction Machine Learning

- Rachat de la société Prevert
- Introduit dans la Version 5.4, fonctionnalités X-Pack
- Permet de se poser les questions :
 - Certains de mes services ont-ils changé de comportement ? »
 - « Y a-t-il des processus inhabituels qui s'exécutent sur mes machines ?
- Basé sur des modèles comportementaux, permet la la détection d'anomalies dans des données temporelles

Principe

- Les données relatives au temps sont extraites d'ElasticSearch pour analyse :
 - soit de façon continue
 - soit périodiquement
- Les résultats anormaux sont affichés dans Kibana.
- Différentes situations sont alors remontées :
 - Anomalies liées à des écarts temporels dans les valeurs, les décomptes ou les fréquences
 - Des raretés statistiques
 - Des comportements inhabituels pour un membre d'une population

Valeurs actuelles, limites normales et anomalies



Anticipation

- Les profils extraits du passé peuvent être utiliser pour anticiper le futur.
- Par exemple, prévoir :
 - Le nombre de visites d'un site web dans 1 mois
 - Quand mon disque atteindra 100 % d'utilisation
- Ces prévisions peuvent être visualisées dans Kibana

Intervalle de prévisions en jaune



Tâches d'analyse

- Les *Machine Learning jobs* contiennent les informations de configuration nécessaire à une tâche d'analyse.
 - Chaque job a un ou plusieurs détecteurs correspondant à une fonction analytique sur certains champs de donnée
 - Il contient également des propriétés indiquant quels événements doivent être analysés par rapport à des comportements précédents ou une population
- Kibana propose des assistants permettant de créer ce type de job
- Les jobs peuvent également être groupés afin de visualiser ensemble leurs résultats
- Les jobs sont exécutés sur des nœuds du cluster qui ont les propriétés de configuration xpack.ml.enabled et node.ml positionnées à true

Fonctions analytiques

• Fonction de :

- Comptage : Détecte des anomalies lorsque le nombre d'événements dans un groupement est anormal
- Géographiques : Détecte les anomalies dans l'emplacement géographique d'une donnée
- Sur le **contenu** : Détecte les anomalies dues au volume d'une donnée String
- **Métriques** : Anomalies sur des moyennes, des min, des max.
- Détection de rareté : Anomalies qui arrivent rarement sur le temps ou rarement dans une population
- **Somme**: Anomalies lorsque la somme d'un champ dans un groupement est anormal
- Temporelle : Détecte des événements qui arrivent à des moments inhabituels. Exemple une week-end

Flux de données

- Les flux de données d'entrée d'un job d'analyse sont créés
 - Soit à partir d'un index pattern ElasticSearch (Typiquement, lorsque l'on utilise Kibana)
 - Soit programmatiquement via une API
- Un job n'est associé qu'à un seul flux de donnés d'entrée
- Dans la cas d'ELS, les flux de données doivent être démarrés (et arrêtés) ; cela est fait via Kibana

Buckets

- Les buckets sont utilisés pour diviser les séries temporelles en traitement par lots
- Ils font partie de la configuration d'un job et déterminent l'intervalle de temps utilisé pour agréger les données.

En particulier, calculer un score d'anomalie

Événements hors norme

- Il est possible de planifier des périodes où l'activité d'événements sera inhabituelle.
 (Par exemple : black fridays ou autre)
- Dans ce cas, les tâches d'analyse ne détectent pas d'anomalies